# 탐색적 자료 분석과 통계 이해

2026

Industrial Data Science Lab & Unique AI

# 1. 데이터의 이해

## 데이터의 값

- 수치형: 1,2,3,4,5,….  1.1,2.4,3.1,…
- 논리형: True or False
- 범주형: "합격" 또는 "불합격" 등
- 텍스트: "오늘의 뉴스는…"

정형 / 반정형 / 비정형 데이터

Structured / Semi Structured / Unstructured

- **정형 데이터의 유형**

**1) 질적 자료(qualitative data=비계측자료 : nonmetric data)**

- 범주형 자료(categorical data) : 예) 거주지, 성별, 등
- 측정척도에 의한 구분
  - ① 명목자료(nominal data)
    - » 범주간 순서가 없음 : 예) 성별, 거주지, 등
  - ② 순서자료(ordinal data)
    - » 범주들 간에는 순서가 있는 자료, 사칙연산을 할 수 없음
      예) 서비스 선호도(5점 척도) 등

**2) 양적 자료(quantitative data=계측자료 : metric data)**

- 수치자료, 사칙연산 가능
- 합계, 평균, 최대값, 최소값, 분산 등으로 자료를 요약/정리 가능
- 예 : 요금, 데이터 사용량 등

# 1. 데이터의 이해

- **분석 대상 데이터는 여러 개의 관측된 개체가 있고, 개체 마다 속성이 있음**
  - 관측된 개체는 데이터의 행으로, 속성은 데이터의 열로 고려하며, 속성을 변수로 이해

① 관측된 개체
- Observation=Case=individual=object

② 개체의 속성
- Variable=attribute=feature=item(Qualitative variable: nominal, ordinal / Quantitative variable: interval)
  - 종속변수=Dependent variable=response variable=target variable=Y 변수
    - » 다른 변수에 의해 영향을 받는 변수
  - 독립변수=설명변수=Independent variable=explanatory variable=input variable=X 변수
    - » 종속 변수에 영향을 주는 변수

# 2. 통계 이해

- **통계학?**

  1) 모수(parameter) : 불변
    - 모집단의 특성을 수치로 나타낸 척도
    - 모수들은 전수조사(census)를 통해 얻은 자료로부터 구해짐.
    - 모집단의 평균인 모평균(population mean) : $\mu$
    - 모집단의 분산인 모분산(population variance) : $\sigma^2$

  2) 통계량(statistic) : 가변
    - 표본자료로부터 얻어진 표본의 특성을 수치로 나타낸 척도
    - 표본의 평균인 표본평균(sample mean) : $\bar{X}$
    - 표본의 분산인 표본분산(sample variance) : $S^2$

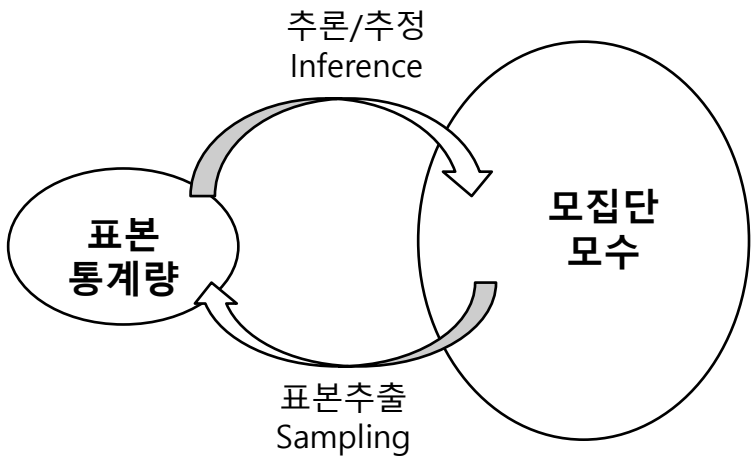

- **모집단과 표본**

**1) 모집단 (Population)**

– 얻고자 하는 정보와 관련 있는 모든 개체로 부터 얻을 수 있는 모든 관측값들의 집합, 관심을 갖는 대상 전체

– 조사 및 관심의 대상이 되는 원소 하나 하나의 전체 집합(모임)

– 모집단은 일반적으로 매우 크고, 실제로 무한히 클 수도 있음

– 모집단 전체를 조사해서 얻은 통계자료를 모집단자료(Population data)

**2) 표본 (Sample)**

– 모집단의 일부분으로 원하는 정보를 얻기 위해 수행한 관측을 통해 얻어진 관측값

– 표본 공간 : 통계적 실험에서 모든 가능한 실험결과들의 집합

– 모집단의 특성을 파악하기 위하여 추출된 모집단의 일부. 즉, 모집단의 부분집합(subset)

– 모집단의 일부분인 표본으로부터 조사된 자료를 표본자료(sample data)라고 함.

# 2. 통계 이해

- **통계량: 자료의 정리 및 요약**

*통계적 분석은 자료의 분포가 가지고 있는 특성을 찾아내서 그 특성을 숫자로 표시하기 위한 작업*

- 분포의 특성
  - 집중화 경향 (중심값 - 산술평균, 중앙값, 최빈값): 자료가 어느 위치에 집중되어 있는가를 나타냄
  - 산포도 (범위, 분산, 표준편차, 백분위수):자료가 산술평균을 중심으로 흩어져 있는 정도

| 이름 | 성별 | 나이 | 거주지 | 직업 | 요금 | 데이터 사용량 | 휴대폰 선호도 | 서비스 선호도 |
|---|---|---|---|---|---|---|---|---|
| AAA | F | 20 | 서울 | 회사원 | 55000 | 3GB | LG | 5 |
| BBB | F | 19 | 인천 | 자영업 | 45000 | 9GB | 삼성 | 4 |
| CCC | M | 25 | 김포 | 회사원 | 35000 | 1GB | 샤오미 | 3 |
| DDD | F | 42 | 대전 | 회사원 | 75000 | 4GB | LG | 5 |
| EEE | F | 27 | 서울 | 자영업 | 65000 | 2GB | 소니 | 4 |
| FFF | M | 20 | 서울 | 회사원 | 55000 | 3GB | LG | 5 |
| GGG | M | 43 | 서울 | 자영업 | 45000 | 9GB | 삼성 | 4 |
| HHH | M | 25 | 대전 | 회사원 | 95000 | 11GB | 샤오미 | 3 |
| III | F | 42 | 김포 | 회사원 | 45000 | 3GB | LG | 5 |
| JJJ | F | 27 | 인천 | 자영업 | 40000 | 4GB | 소니 | 4 |

# 2. 통계 이해

- **기술통계**
  - Descriptive Statistics
  - 자료의 특성을 표, 그림, 통계량 등을 사용하여 쉽게 파악할 수 있도록 정리/요약, 자료를 요약하는 기초적 통계
  - 예:
    - 중심위치의 측도: 표본평균, 중앙값
    - 산포의 측정: 분산, 표준편차,사분위범위수, 백분위수, 변동계수, 평균의 표준오차
    - 분포의 형태에 관한 측도: 왜도(양수->왼쪽으로 치우친, 음수->우측으로 치우친),첨도

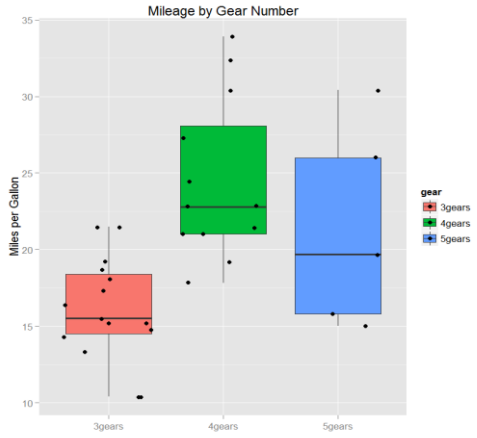


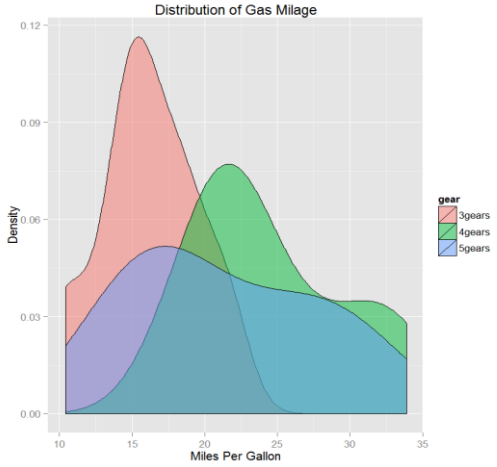

# 2. 통계 이해

- **추론통계**
  - Statistical Inference
  - 모수 추정(Parameter estimation)
    - 점추정(Point Estimation): 모수가 특정한 값일 것이라고 추정, 표본의 평균/중위수/최빈값 등을 사용, 불편성/효율성/일치성/충족성
    - 표본 평균과 표본 분산
    - 구간추정(Interval Estimation): 점추정의 정확성을 보완하기 위해 확률로 표현된 믿음의 정도 하에서 모수가 특정한 구간에 있을 것이라고 선언
    - 추정량의 분포에 대한 전제 필요, 구해진 구간 내 모수가 있을 가능성의 크기(신뢰수준) 필요
    - 예: 95% 신뢰수준 하에서 모평균의 신뢰구간

  - 가설검정(Hypothesis Test)
    - 모집단에 대한 어떤 가설을 설정한 뒤, 표본 관찰을 통해 가설의 채택여부 결정
    - 표본관찰이나 실험을 통해 귀무가설과 대립가설 중 택1
    - 귀무가설이 옳다는 전제 하 검정통계량을 구하여, 이 값이 나타날 가능성의 크기로 판단

    - 귀무가설/대립가설/검정통계량/유의수준/기각역/채택역
    - 제1종 오류/제2종 오류

# 3. 통계량의 이해

- 집중화 경향: 자료가 어느 위치에 집중되어 있는가를 나타냄, 평균, 중앙값 등이 있음

- 예를 들어, 평균은 집중화 경향에 대한 자료의 특성을 대표할 수 있는 값으로, 모든 관측값을 더해서 관측값 개수로 나누어 구하고, 중앙값은 어떤 주어진 값들을 크기의 순서대로 정렬했을 때 가장 중앙에 위치하는 값

# 3. 통계량의 이해

- **Measure of central tendency**
  - **평균(mean)**
    - (산술)평균(mean; arithmetic mean; average), 균형점(자료의 중심),
      모든 관측값의 크기(정보)를 반영, 이상값(outlier)의 영향을 받음.

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

  - **중앙값(Median)**
    - 자료를 관측값의 크기순으로 배열하였을 경우, 중앙에 위치하는 관측값 이상값에 덜 민감
    - 관측값의 수가 짝수이면 중앙의 두 관측값을 평균함.
    - 50% percentile

  - **최빈값(mode)**
    - 자료 중에서 가장 많이 출현하는 관측값
    - 명목자료인 경우 평균과 중앙값은 무의미(예 : 허리사이즈)
    - 존재하지 않을 수도 있으며, 1개 이상 존재할 수도 있음.

# 3. 통계량의 이해

- **Measure of dispersion**
  - **필요성**
    - 자료를 대표값으로 요약/정리하는 것 만으로 충분하지 않음
    - 자료에서 관측값들이 얼마만큼 퍼져있는가를 측정하는 척도인 산포도를 고려
    - 산포도는 자료에서 관측값들이 변화하는 크기인 변동량을 나타내는 값

  - **범위(range)**
    - 자료의 관측값 중 가장 큰 값인 최대값(max)과 가장 작은 값인 최소값(min)과의 차이
    - 범위(range)=최대값(max)-최소값(min)
    - 자료들 중 두 관측값만 이용하며 관측값 하나 하나의 크기가 반영되지 못함.
    - 이상값에 의해 크게 영향 받음.

# 3. 통계량의 이해

- **Measure of dispersion**

**- 백분위수와 사분위수**

- 평균과 표준편차는 자료의 분포에 대해 중요한 정보를 제공하지만, outlier 등의 영향을 받을 수 있으며,
  자료 분포의 치우침 등에 대한 정보는 아님.
- Outlier나 Skewness 등에 영향을 받지 않고 자료를 파악하기 위해 median이나 interquartile range 등을 활용

– **백분위수(Percentile)**

- 자료를 크기 순서에 따라 나열한 자료를 100등분하는 수로, X 분위값이란 자료가 X%보다 작거나 같게 되는 값

– **사분위수(Quartile)**

- 백분위수가 25%, 50%, 75%인 경우

# 3. 통계량의 이해

- **Measure of dispersion**
  - **분산과 표준편차**
    - 두 통계량 모두 각 자료가 평균에서 얼마나 퍼져있는지를 보는 정도, 관측값들이 자료의 중심인 평균으로부터 얼마나 떨어져 있는가의 척도, 즉 평균과 차이들의 평균
  - **분산(Variance)**
    - 각 자료가 평균에서 얼마나 퍼져있는지를 보는 정도. 각 자료의 평균과의 차이에 대한 평균
    - 모분산(population variance): 모집단으로부터 전수조사를 하여 얻은 관측값인 경우 모집단의 분산
      - » $\sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(X_i - \mu)^2$
  - **표본 분산(sample variance)**
    - $S^2 = \frac{1}{n-1}\sum_{i=1}^{N}(X_i - \bar{X})^2$
  - **표준편차**
    - 모분산이나 표본분산은 관측값들의 편차를 제곱하여 계산하므로 모분산이나 표본분산의 측정단위는 관측값들의 측정단위와 일치하지 않으며, 그렇기 때문에 관측값의 측정단위와 일치시키기 위해서는 분산의 양의 제곱근을 사용

# 3. 통계량의 이해

- **Measure of dispersion**
  - **공분산 (Covariance)**
    - 분산은 한 변수에 대한 자료의 퍼짐이며, 두 변수간의 관계를 알기 위해 공분산을 사용
    - 공분산은 X, Y가 각각의 평균들로부터 떨어진 거리, 변수의 편차간의 곱의 평균

$$\sigma(x, y) = \mathrm{E}\left[(x - \mathrm{E}[x])(y - \mathrm{E}[y])\right],$$

# 3. 통계량의 이해

- **공분산**
  - 두 변수의 상관(하나가 증가할 때 다른 하나는 감소하거나, 하나가 증가할 때 다른 하나도 증가하는 등의 관계) 정도를 나타내는 값

- **공분산의 해석**

  - 공분산 > 0
  - 공분산 = 0
  - 공분산 < 0

- **Measure of dispersion**
  - **상관관계:**
    - 두 변수의 공분산을 각 변수의 편차로 나눠서 -1~1 사이로 조정한 값
    - Scaled version of the covariance between X and Y
    - Pearson correlation

$$\sigma(x, y) = \mathrm{E}\left[(x - \mathrm{E}[x])(y - \mathrm{E}[y])\right],$$

    - 상관관계는 -1~1사이의 값으로 Scale되며, 1은 두 변수 간 강한 상관관계가 있음을, 0은 두 변수가 관계가 없음을, -1은 두 변수간 음의 상관관계가 강하게 있음을 의미

$$R = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum(X_i - X)^2 \sum(Y_i - Y)^2}}$$

# 3. 통계량의 이해

- **기대값, 평균, 분산**
  - $\mu = E(X) = \int_{-\infty}^{\infty} xf(x)dx$
  - $\sigma^2 = V(X) = E[(X-\mu)^2] = \int_{-\infty}^{\infty}(X-\mu)^2 xf(x)dx = E\left(X^2\right) - \mu^2$
  - $E(aX) = aE(X)$
  - $V(aX) = a^2\mathrm{V(X)}$

# 4. 확률

- **확률(Probability)**
  - 불확실성을 나타내는 측도(measure)로 0~1의 값으로 표현
  - 확률(probability)은 어떤 특정한 사상이 발생할 가능성을 숫자로 나타낸 측정치임.
    즉, 사상의 발생할 가능성을 말함.
  - Random한 실험에서 실험결과가 항상 동일하지 않으므로 불확실성이 있으며, 이것을 확률로 측정

- **독립성**
  - 두 사건 A, B에 대해 P(A and B)=P(A)P(B)이면 A와 B는 서로 독립

(두 사건이 독립이 아닌 경우)

- **조건부 확률**
  - 하나의 사건이 일어났을 때, 이 사건이 다른 사건과 **관련이 있는 경우** 사용되는 방법.
  - A가 주어졌을 때, B가 일어날 조건부 확률은 P(B|A)로 표시하며 P(A)>0 면,

$$P(B \mid A) = \frac{P(A \cap B)}{P(A)}$$

  - A, B 가 서로 배반이면
    - P(A∪B) = P(A)+P(B)이고, P(A∩B) = 0

# 4. 확률

- **A, B에 대해서**
  - $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
  - A, B가 exclusive $\Leftrightarrow A \cap B = \emptyset \Leftrightarrow P(A \cap B) = 0 \Leftrightarrow P(A \cup B) = P(A) + P(B)$
  - 조건부 확률
    - $P(A|B) = P(A \cap B) / P(B)$
    - 승법정리: $P(A \cap B) = P(B)P(A|B) = P(A)P(B|A)$
  - A, B가 statistically independent $\Leftrightarrow P(A \cap B) = P(A)P(B) \Leftrightarrow P(A|B) = P(A) \Leftrightarrow P(B|A) = P(B)$

- **조건부 확률 (두 사건이 독립이 아닌 경우)**
  - 하나의 사건이 일어났을 때, 이 사건이 다른 사건과 **관련이 있는 경우** 사용되는 방법.
  - A가 주어졌을 때, B가 일어날 조건부 확률은 P(B|A)로 표시하며 P(A)>0 면,

$$P(B \mid A) = \frac{P(A \cap B)}{P(A)}$$

$P(A \cap B) = P(A)P(B|A) = P(B)P(A|B)$ multiplication rule

  - 표본공간이 S에서 A로 바뀐 것을 의미
  - A, B 가 서로 배반이면

$P(A \cup B) = P(A)+P(B)$이고, $P(A \cap B) = 0$

$P(A_1 \cup A_2 | B) = P(A_1 | B)+P(A_2 | B)$

# 4. 확률

- **두 사건의 독립**
  - 두 사건 A, B에 대해 $P(A \cap B) = P(A)P(B)$이면 A와 B는 서로 독립

- **조건부 독립**
  - $P(H) > 0$ 인 사건 H와 두 사건 A, B에 대해 $P(A \cap B|H) = P(A|H)P(B|H)$이면 A와 B는 H가 주어진 조건하에서 서로 조건부 독립

  - H가 주어졌을 때, A가 추가되는 것은 B에 대한 정보를 아는데 영향을 미치지 않음.

# 5. 확률변수와 확률 분포

- **확률변수** : 측정치로부터 얻을 수 있는 값의 총 집합을 표본공간이라 하는데, 표본 공간상의 각각의 값에 실수를 부여하는 함수

- **확률분포** : 확률변수가 취할 수 있는 모든 값들에 대해 이들 값들이 취할 수 있는 확률을 그림이나 표(함수식)로 나타낸 것

  1) 이산확률분포 : 불량수나 결점수와 같이 셀 수 있는 확률변수에 대응되는 확률분포

  2) 연속확률분포 : 제품이 중량이나 치수와 같이 셀 수 없는 연속값을 갖는 확률분포

- **Distribution**
  - 예2: 동전을 두 번 던진다면?
    - 확률변수는 앞면의 횟수로 고려

| Sample Space(S) | R.V. (X) | P(X=x) |
|---|---|---|
| H,H | 2 | 0.25 |
| H,T | 1 | 0.25 |
| T,H | 1 | 0.25 |
| T,T | 0 | 0.25 |

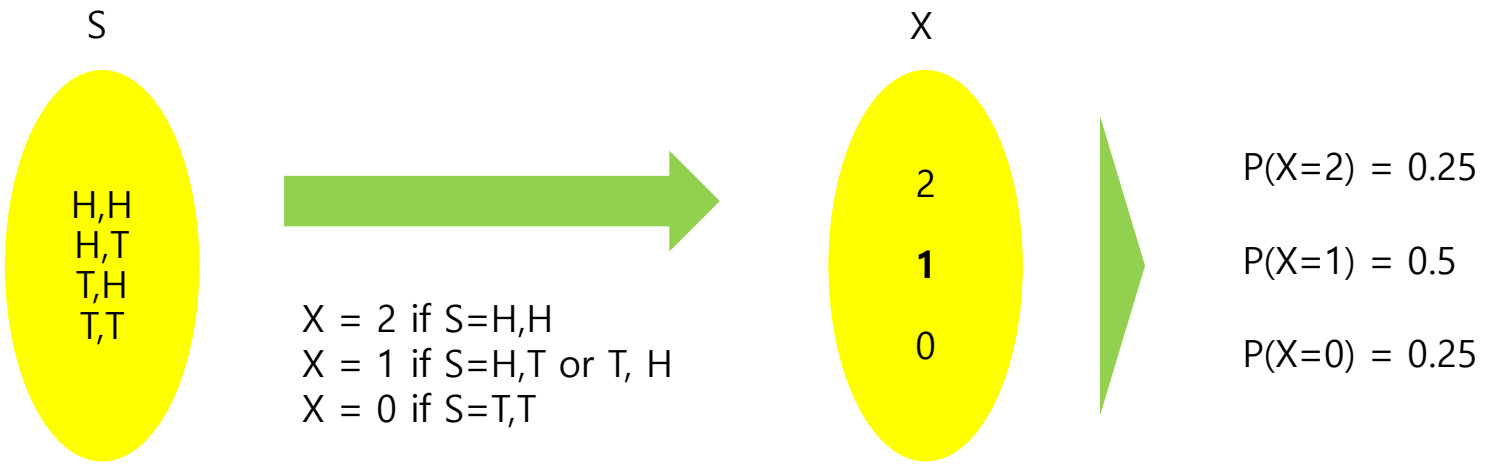

# 5. 확률변수와 확률 분포

- 조건부 확률의 확률분포

- 결합확률분포

| | X | | |
|---|---|---|---|
| Y | 1 | 2 | 3 |
| 1 | 0.2 | 0.3 | 0.2 |
| 2 | 0.1 | 0.1 | 0.1 |

- 주변확률분포

| x | 1 | 2 | 3 |
|---|---|---|---|
| $f_X(x)$ | 0.3 | 0.4 | 0.3 |

| y | 1 | 2 |
|---|---|---|
| $f_Y(y)$ | 0.7 | 0.3 |

- Y가 주어진 X의 조건부 분포 f(x|y) = f(x,y) /f(y)

| x | 1 | 2 | 3 |
|---|---|---|---|
| $f(x\|y=1)$ | 0.2/0.7 | 0.3/0.7 | 0.2/0.7 |
| $f(x\|y=2)$ | 0.1/0.3 | 0.1/0.3 | 0.1/0.3 |

- X, Y는 독립?
- $f_{XY}(1,1) = 0.2$
- $f_X(1) = 0.3$
- $f_y(1) = 0.7$

# 5. 확률변수와 확률 분포

- **이항분포(binomial distribution)**

베르누이 시행의 조건 -예) 동전 던지기

1) 시행의 결과는 한 사건은 성공(S), 다른 사건은 실패(F)로서 상호 배타적인 두 사건
2) 각 시행에서 성공이 나타날 확률은 p=P(S), 실패가 나타날 확률은 q=P(F)=1-p
   성공과 실패가 나타날 확률의 합은 p+q=1
3) 각 시행은 서로 독립적
4) 확률밀도함수: $p^x(1-p)^{n-x}$
   X~Ber(p), E(X) = p, Var(X) = p(1-p)

***<u>이항분포는 여러 번의 베르누이 시행을 할 때 나타나는 분포</u>***

- 이항분포의 확률 밀도 함수 X~B(n, p )
- E(X) = np, Var(X) = np(1-p)

$$P(X=x|p)= \binom{n}{x}p^x(1-p)^{n-x} = {}_nC_x p^x(1-p)^{n-x}$$

$$\binom{n}{x} = \frac{n!}{x!(n-x)!}$$

# 5. 확률변수와 확률 분포

- **포아송분포(Poisson distribution)**

단위시간이나 단위공간에서 특정 사건이 드물게 발생될 때

- 강판, 직물 등의 연속체에 평균 m개의 흠이 있을 때,
- 랜덤하게 일정 단위를 채 취하여 흠을 조사할 때, 흠이 x개 나타날 확률
- 단위시간 내에 은행에 찾아오는 고객의 수,
- 어느 지역의 하루 교통사고 수

포아송분포의 밀도함수

$$P(X=x) = \frac{e^{-m}\, m^{x}}{x!}$$

m : 평균발생횟수
x : 사건발생횟수

- 포아송 분포의 특성

-이항분포에서 $p<0.1$일 때, 포아송분포로 변화

-포아송분포에서 $m>5$일 때, 정규분포로 변화

# 5. 확률변수와 확률 분포

- **정규분포(Normal distribution)**

1) 정규분포의 모양과 위치는 분포의 평균과 표준편차로 결정

2) 정규분포의 확률밀도함수는 평균을 중심으로 대칭인 종 모양

3) 정규곡선은 X축에 맞닿지 않으므로 확률변수 X가 취할 수 있는 값의 범위는 $-\infty < X < +\infty$이다
(관측값의 99.7%가 $\pm 3\sigma$안에 속해 있다)

4) 분포의 평균($\mu$)과 표준편차($\sigma$)가 어떤 값을 갖더라도 정규곡선과 X축사이의 전체면적은 1이다

■ 정규분포의 밀도함수

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-(x-\mu)^2}{2\sigma^2}}$$

$-\infty < x < \infty$, $\pi$: 3.142(원주율), e: 2.7183

# 5. 확률변수와 확률 분포

- **표준정규분포**
  - 표준정규분포는 정규분포를 평균 $\mu=0$, 표준편차$\sigma=1$이 되도록 **표준화** 한 것.
  - 어떤 관측값 X의 값이 그 분포의 평균으로부터 표준편차의 몇 배 정도나 떨어져 있는가를
  - 다음과 같이 표준화된 확률변수 Z로 나타내며, $N(0,1^2)$으로 표시한다.

$$Z = \frac{X - \mu}{\sigma}$$

Z=0부터 Z=1.5사이에 확률변수가 있을 확률

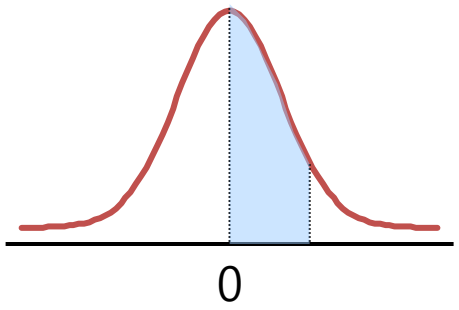


$P(0 \le Z \le 1.5) = 0.4332$

Z=0에서 ±45%에 해당하는 Z값

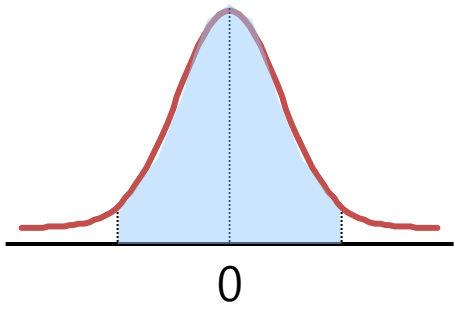


$Z = \pm 1.6449$

Z=-2보다 작거나 Z=2보다 큰 사이에 확률변수가 있을 확률

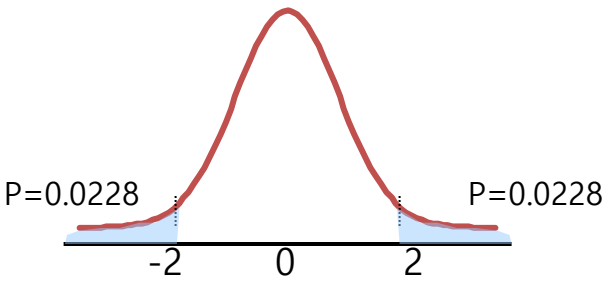


$P(-2 \ge Z, Z \ge 2) = 0.0456$

- **Γ – 분포**

  - 양의 실수 영역에서 정의된 연속확률분포, 다양한 실세계 현상을 모델링할 때 유용
  - PDF

$$f(x;\alpha,\beta) = \frac{1}{\Gamma(\alpha)\beta^{\alpha}} x^{\alpha-1} e^{-x/\beta}, \quad x > 0$$

    - a: 형상 모수(shape parameter), b:척도 모수(scale parameter), $\lambda$: 비율 모수(rate parameter, 1/b)
    - $\Gamma(\alpha)$는 감마 함수로, 정수 $n$에 대해서는 $\Gamma(n) = (n-1)!$
    - $E(X) = \alpha\beta, \ V(X) = \alpha\beta^2$
      - $\alpha = 1$이면 지수분포

    - 활용:
      - 지수분포의 일반화: 지수분포는 감마분포의 특별한 경우
      - 대기시간 모델링: 사건이 여러 번 일어나는 데 걸리는 총 대기시간을 설명
      - 비대칭 데이터 모델링: 평균보다 큰 극단값이 자주 나타나는 데이터(오른쪽 꼬리)가 있는 경우 적합

- **지수 분포**

  - 지수분포(Exponential Distribution)
    - 어떤 사건이 발생할 때까지 걸리는 시간을 모델링
    - 포아송 과정과 밀접한 관계가 있어, 시간 간격이나 대기 시간과 관련된 현상에서 널리 활용
    - PDF
    - $$f(x;\lambda) = \lambda e^{-\lambda x}, \quad x \geq 0$$
    - $\lambda > 0$, rate parameter이며 단위시간당 사건이 발생하는 평균 횟수
    - $E(X) = \frac{1}{\lambda} \quad V(X) = \frac{1}{\lambda^2}$
    - memoryless
      - P(X> s+t | X>s) = P(X>t)
    - 활용
      - 다음 버스 올 때까지의 시간, 기계가 고장 나기까지의 시간, 패킷이 수신될 때까지의 시간, 사건 간의 시간 간격

# 5. 확률변수와 확률 분포

- **포아송, 감마, 지수 분포**

  - 포아송 분포: 일정한 시간 내 발생한 사건의 횟수, 사건의 개수
  - 지수 분포: 다음 사건이 발생할 때까지 걸리는 시간, 사건 간의 시간 간격
  - 감마분포: n번째 사건이 발생할 때까지 걸리는 총 시간, 누적 대기시간(지수분포의 합)

  - 예: 버스가 평균적으로 10분에 1대씩 오는 경우, $\lambda = \frac{1}{10}$
    - 다음 버스를 기다리는 시간: 지수 분포
    - 3번째 버스가 오기까지 걸리는 시간: 감마 분포
    - 30분동안 버스가 몇 대 왔는지: 포아송 분포

# 5. 확률변수와 확률 분포

- **t – 분포(서로 다른 두 집단의 평균의 통계 검정)**

  - 정규분포로부터 확률표본이 크지 않고 표준편차(σ)를 모를 때

$$t = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$ 는 자유도 n-1인 t-분포를 따름.

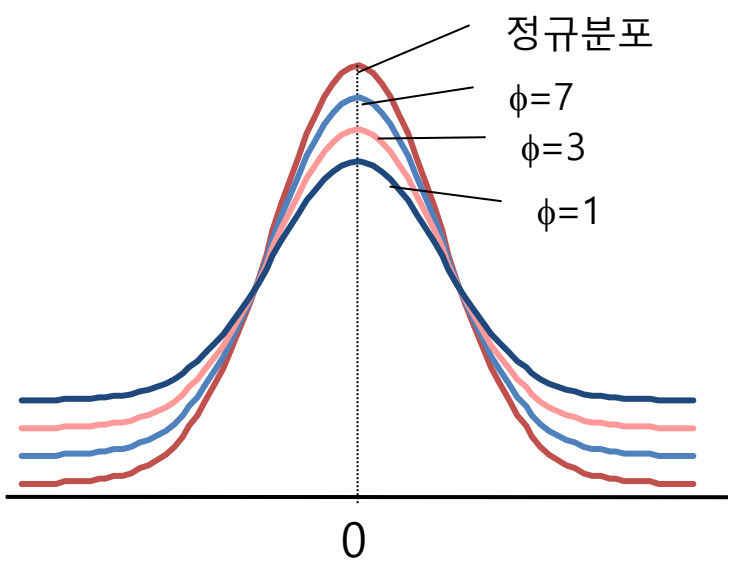


- T-분포의 특징
  - t분포는 정규분포보다 퍼져 있으며 자유도(ϕ)가 커질수록 정규분포에 근접
  - 표본의 크기가 작아 표본의 표준편차(s)가 모집단의 표준편차(σ)보다 불확실성이 크기 때문
  - 표본의 크기 n이 커질수록 표본의 표준편차가 모집단의 표준편차에 접근하기 때문
  - t분포는 자유도에 따라 달라지며 자유도는 표본의 크기에서 1을 뺀 것으로 n-1로 표시

# 5. 확률변수와 확률 분포

- $\chi^2$ - 분포(서로 다른 2개 이상 집단의 비율의 통계 검정)
  - 단일 모집단의 분산의 표본분포는 $\chi^2$분포를 이용하여 나타낼 수 있음
  - 두 모집단의 분산의 표본분포는 F분포를 이용하여 나타낼 수 있음

  - 정규모집단 $N(\mu, \sigma^2)$으로부터의 확률표본 X1, X2,....Xn에 대해
  - $\chi^2 = \dfrac{\Sigma(X_i - \overline{X})^2}{\sigma^2} = \dfrac{(n-1)S^2}{\sigma^2}$의 분포를 자유도 n-1인 $\chi^2$분포라 한다.

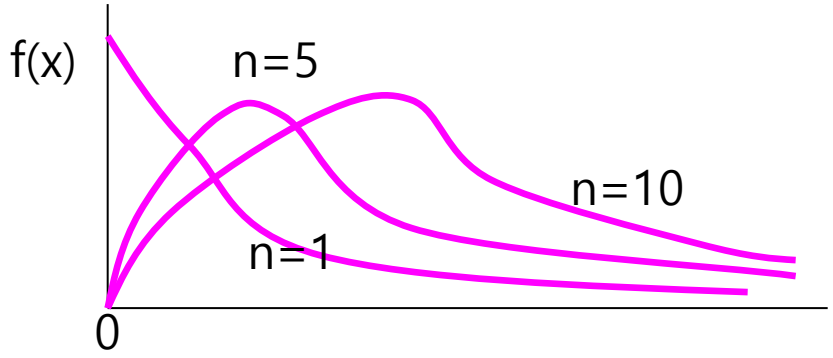

# 5. 확률변수와 확률 분포

- **F - 분포(서로 다른 2개 이상 집단의 분산의 균질성 검증)**

  - 모집단이 정규분포를 이루며 각각 $\sigma_1^2$, $\sigma_2^2$라는 분산을 갖는 두 개의 모집단에서 각각 크기가 $n_1$, $n_2$인 두 표본을 추출하여 표본분산을 계산
  - 두 표본분산이 $S_1^2$, $S_2^2$이라고 할 때, 표본분산과 모분산의 비율로 이루어진 두 개의 $\chi^2$의 비율은 F분포를 이루며, F분포는 두 개의 자유도를 갖음

$$\chi_1^2 = \frac{(n_1-1)S_1^2}{\sigma_1^2} \sim \chi_1^2\ (n_1-1)$$

$$\chi_2^2 = \frac{(n_2-1)S_2^2}{\sigma_2^2} \sim \chi_2^2\ (n_2-1)$$

$$\frac{\chi_1^2 / (n_1-1)}{\chi_2^2 / (n_2-1)} = \frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} \sim F(n_1-1,\ n_2-1)$$

  - 위의 식에서 F분포는 두 모집단의 분산을 비교하는 것임을 알 수 있음

# 6. 통계 검정

- **통계적 가설 검정(Hypothesis Testing)**

  - 가설 검정 = 가설(Hypothesis) + 검정(Testing)

  - 가설검정이란?
    - 표본(Sample)으로부터 주어지는 정보를 이용하여, 모수에 대한 예상 혹은, 주장 또는 단순한 추측 등의 옳고 그름을 확률적인 개념을 이용하여 판정하는 과정

  - 가설(Hypothesis)
    - 귀무가설(Null Hypothesis ; $H_0$)
    - "Equal(=) ; 같다"
      - 과거부터 알려져 왔던 모수에 대한 일반적인 내용

    - 대립가설(Alternative Hypothesis ; $H_1$)
      - "Not Equal(≠) ; 다르다"
      - 자료로부터 강력한 증거에 의하여 입증하고자 하는 내용

- **가설 검정 절차**

| | |
|---|---|
| •Step #1 | 가설 설정<br>귀무가설($H_0$)과 대립가설($H_1$)을 세운다. |
| •Step #2 | 검정 통계량(Test Statistics) 산출 or 유의 수준($\alpha$) 결정 |
| •Step #3 | 기각치(Critical Value) 산출 or P-Value 산출 |
| •Step #4 | 귀무가설($H_0$)의 기각 여부 결정<br>If P-Value < 유의수준($\alpha$)이면, 귀무가설 ($H_0$) 기각 |
| •Step #5 | 기술적 용어로 해석 |

Significance level, 귀무가설을 기각하게 되는 확률의 크기,
귀무가설이 옳음에도 이를 기각하는 확률의 크기

# 6. 통계 검정

- **통계적 가설 검정**
  - 오류가 발생할 수 있음
  - 오류는 다음과 같이 제1종 오류와 제2종 오류로 나누어 고려

  - 제1종 오류: Type I error
    - 귀무가설(H0)이 참이지만, 기각된 경우 발생
    - False positive로 이해할 수 있음
    - 제 1종 오류의 수준은 α (alpha)로 표시하며, alpha level 또는 유의수준(significance level)으로도 사용
    - 유의수준은 일반적으로 0.05 (5%)로 사용하며, (True임에도) 귀무가설을 잘못 기각하는 확률을 5%까지는 용인한다는 의미

  - 제2종 오류: Type II error
    - 귀무가설이 거짓임에도, 기각을 못한 경우 발생
    - False negative로 이해
    - 제2종 오류의 수준은 β (beta)로 표시하며, 검정력(1−β)과 관련있는 것으로 고려

# 6. 통계 검정

- **정규성 검정 - Normality Test**
  - 목적
    - 대부분의 통계 분석에 있어, 데이터의 정규성을 가정한다.
    - 주어진 데이터의 정규성을 통계적인 방법으로 검정
  - 가설
    - 귀무가설($H_0$) : 정규분포를 따른다.
    - 대립가설($H_1$) : 정규분포를 따르지 않는다.

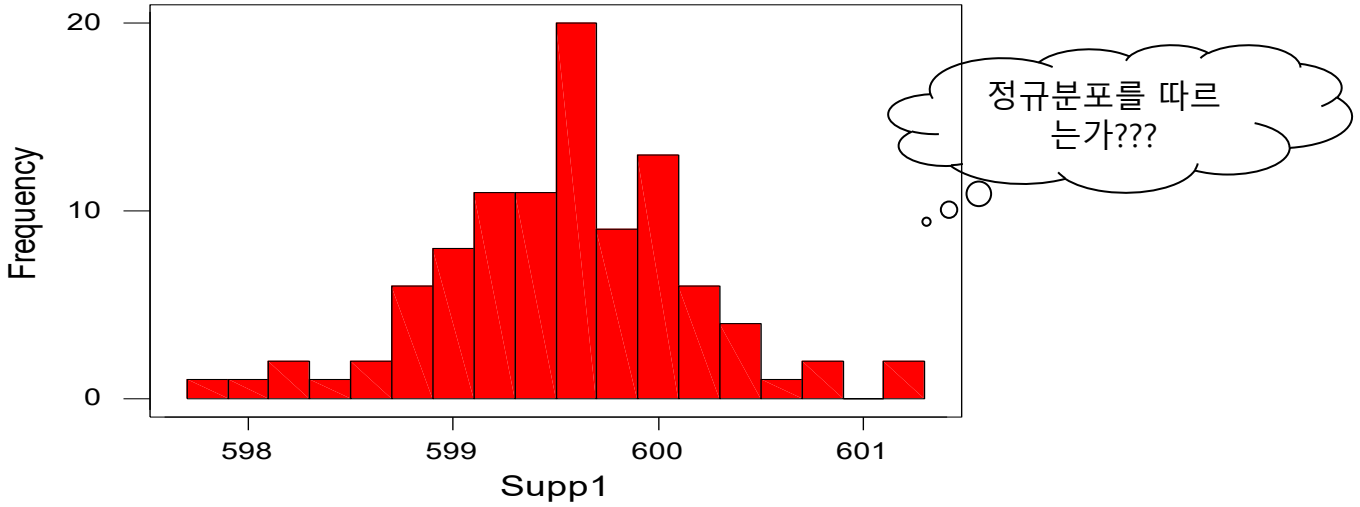

# 6. 통계 검정

- **t-검정 (t-Test)**
  - t-검정: 표본 데이터가 정규 분포를 따른다는 가정 하에 수행
  - 단일 표본 t-검정 (One-Sample t-Test): 한 집단의 평균이 특정 값과 차이가 있는지를 검정
  - 독립 표본 t-검정 (Independent Two-Sample t-Test): 두 독립적인 집단의 평균이 서로 차이가 있는지를 비교.
  - 쌍체 비교 (Paired Sample t-Test): 동일한 집단에 대해 두 번의 측정을 했을 때, 측정 전후 결과의 평균이 서로 다른지를 검정.

- **쌍체 비교(Paired t-Test)**
  - 목적
    - 동일한 모집단을 대상으로 처리 전,후에 차이가 있는지 여부를 통계적인 방법을 이용해서 검정
  - 가설
    - 귀무가설($H_0$) : $\delta = 0$ (두 모집단의 평균은 같다.)
    - 대립가설($H_1$) : $\delta \neq 0$ (두 모집단의 평균은 다르다.)

| X | Y | d(=X-Y) |
|---|---|---|
| $X_1$ | $Y_1$ | $d_1$ |
| $X_2$ | $Y_2$ | $d_2$ |
| : | : | : |
| $X_k$ | $Y_k$ | $d_k$ |

# 6. 통계 검정

- **쌍체 비교(Paired t-Test)**
  - 쌍체 비교의 예
    - 환자들에 대해 새로운 치료법을 적용한 실험 결과
    - 각 환자별로 기록된 수치는 환자들로부터 측정한 약의 효과(높을수록 좋은 수치)를 처치 전/후로 나누어 정리

  - "약의 효과가 있을까?"
    - 새로운 치료법 적용 전후의 효과 차이를 검정하기 위해 Paired T-test를 이용할 수 있음.
    - 귀무가설은 치료법 적용 전후에 효과의 평균 차이가 없는 것을 가정
    - 유의수준이 5%, P-value가 5% 유의수준보다 크면, 새로운 치료법으로 인한 개선 효과는 없다고 볼 수 있음

| | 환자1 | 환자2 | 환자3 | 환자4 | 환자5 | 환자6 | 환자7 | 환자8 | 환자9 | 환자10 |
|---|---|---|---|---|---|---|---|---|---|---|
| 처치 전 | 51.4 | 52 | 45.5 | 54.5 | 52.3 | 50.9 | 52.7 | 50.3 | 53.8 | 53.1 |
| 처치 후 | 50.1 | 51.5 | 45.9 | 53.1 | 51.8 | 50.3 | 52 | 49.9 | 52.5 | 53 |

# 6. 통계 검정

- **범주형 데이터 분석에 활용**
  - 표준 정규 분포를 따르는 독립적인 여러 확률 변수의 제곱합으로 정의
  - 비대칭적이며, 오른쪽으로 긴 꼬리
  - 자유도가 증가함에 따라 분포의 형태는 점점 더 정규 분포와 유사

  - 활용
    - 적합도 검정 (Goodness-of-Fit Test):
      - 관찰된 빈도가 예상 빈도와 얼마나 잘 일치하는지를 평가, 실제 데이터 분포가 기대하는 이론적 분포를 따르는지 검정
    - 독립성 검정(Test of Independence):
      - 두 변수가 서로 독립적인지를 평가
      - 두 범주형 변수 간에 관련이 있는지를 확인 (예: 카이제곱 독립성 검정)
    - 분산 분석:
      - 두 집단의 분산이 동일한지 비교

# 6. 통계 검정

- **F-Test**
  - 두 모집단 간에 산포 차이가 있는지 여부를 통계적인 방법을 이용해서 검정
  - 귀무가설($H_0$) : $\sigma_1^2 = \sigma_2^2$ (두 모집단의 산포는 같음)
  - 대립가설($H_1$) : $\sigma_1^2 \neq \sigma_2^2$ (두 모집단의 산포는 다름)

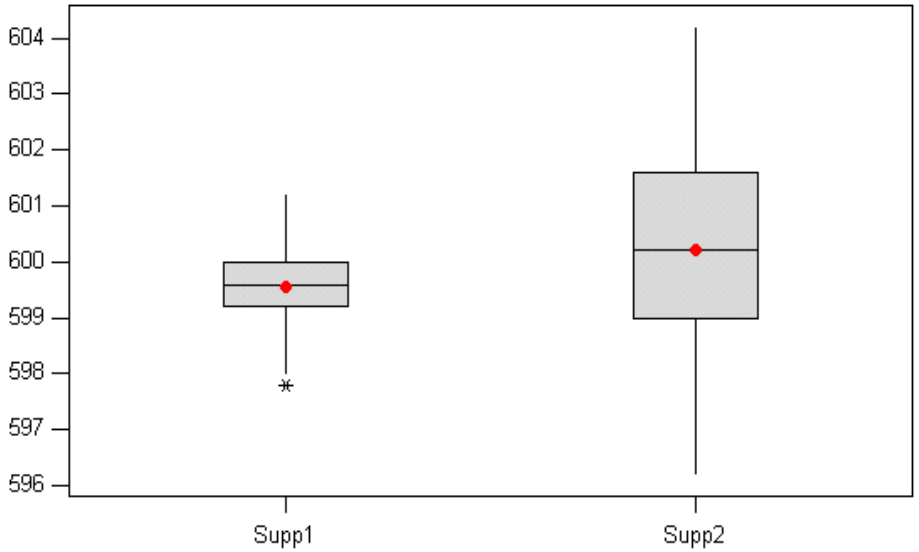


산포 차이가 있나?

# 6. 통계 검정

- **등분산 검정(Test of Equal Variances)**
  - 등분산 검정: 두 모집단 간 혹은 세 집단 이상 간에 산포 차이가 있는지 여부를 통계적인 방법을 이용해서 검정
  - F-검정
    - 가장 기본적인 등분산 검정 방법
    - 두 집단의 분산 비율이 F-분포를 따르는지 검정하여, 두 집단 간 분산을 비교
    - 정규분포를 따라야 함
    - 그 외 Levene's Test, Bartlett's Test 등이 있음.

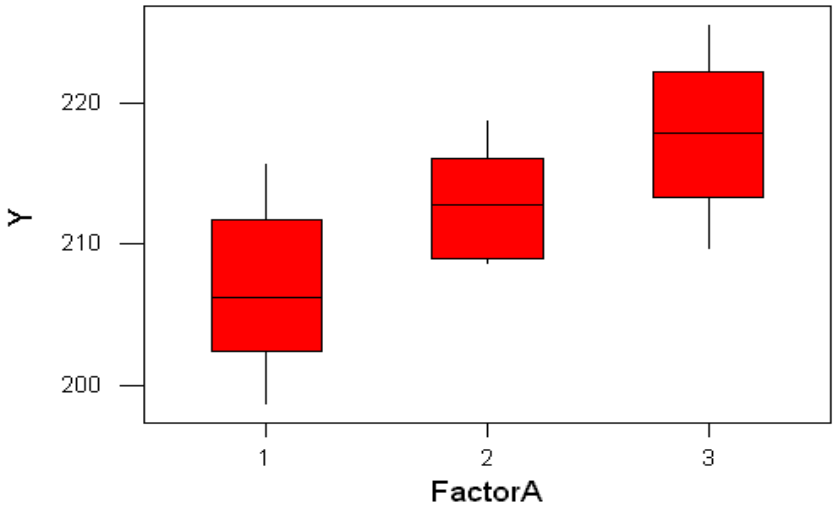


  - 가설
    - 귀무가설 $\sigma_1^2 = \sigma_2^2 = \ldots = \sigma_k^2$
    - 대립가설 $\sigma_i^2 \neq \sigma_j^2$

# 6. 통계 검정

- **A/B 테스트**
  - 두 가지 이상의 대안(A vs B)을 비교해서 어떤 것이 더 좋은 성과를 내는지 검증하는 실험 방법
  - 구성
  - (1) Control vs Treatment
    - A (Control): 기존 방식
    - B (Treatment): 변경안
  - (2) Randomization
    - 사용자들을 무작위로 나눔→ 외생성 확보 (confounding 제거)
  - (3) Outcome (성과 지표)
    - 클릭률 (CTR)
    - 전환율 (Conversion)
    - 체류시간
    - 매출 등

# 6. 통계 검정

- **A/B 테스트**
  - 통계적 검정
    - t-test, chi-square test
  - 인과추론
    - Average Treatment Effect 추정: 인과 관계

- **분산분석(ANOVA : Analysis Of Variance)**
  - 여러 집단의 평균을 비교
    - 2개의 집단에 대한 평균을 비교하는 통계적 기법: t-Test
    - 3개 이상 집단의 평균 비교: 분산분석 (ANOVA : Analysis Of Variance)
  - 분산의 개념 기반하여 분석: 분산 계산 방식처럼 편차들의 제곱합을 해당 자유도로 나누어서 얻게 되는 값을 이용, 범주 각 수준의 평균들간의 차이 존재 여부 판단
  - 영국의 통계학자 피셔(R.A. Fisher)가 고안한 분석 기법, 농업 연구에서 사용이 시작되었으며, 사회과학, 공학, 의학 등 다양한 분야에 폭넓게 적용
  - 모형 구성: 설명변수는 범주형 자료(categorical data), 종속변수는 연속형 자료 (continuous data)

- **일원분산분석 (One-way ANOVA)**
  - 독립변수에 하나의 요인(범주형 변수)만 고려하는 경우 사용
  - 아래와 같은 자료에 대해 적용 (전체 Y 평균: $\bar{Y}$)

| 요인(Factor) | Observation | Mean |
|---|---|---|
| Factor의 Level 1 | $\boldsymbol{Y_{11}}$, $\boldsymbol{Y_{12}}$, ....$\boldsymbol{Y_{1n}}$ | Level 1 관측치의 평균,$\overline{\boldsymbol{Y_1}}$ |
| ... | ... | ... |
| Factor의 Level r | $\boldsymbol{Y_{r1}}$, $\boldsymbol{Y_{r2}}$, ....$\boldsymbol{Y_{rn}}$ | Level 1 관측치의 평균,$\overline{\boldsymbol{Y_r}}$ |

  - 이때, 측정된 각 값인 $Y_{ij} = \mu_i + \varepsilon_{ij}$로 나타나는데
    - i=1,2,...,r 로 Factor의 여러 level 의미
    - j=1,2,...,n으로 각 level에 해당하는 관측치의 개수(level별로 동일하게 설정)
    - $\mu_i$: i번째 수준에서의 평균
    - $Y_{ij}, \varepsilon_{ij}$: i번째 수준에서 측정된 j번째 값이며, 이때의 오차. 특히, $\varepsilon_{ij}$는 서로 독립이며, 정규분포 N($\mu_i$, $\sigma^2$)을 따른다고 가정

- **일원분산분석 (One-way ANOVA)**
  - 분산분석은 관측치의 전체 변동(Sum of Squares)을, 비교하려는 요인 수준(Factor Level) 간 차이에 의해서 발생하는 변동(SSTR)과, 그 외 요인에 의한 변동(SSE)으로 나누어 분석
  - 즉, 측정값과 전체 측정값 평균의 차이는 다음과 같이 나눌 수 있음

$$Y_{ij} - \bar{Y} = (\bar{Y}_i - \bar{Y}) + (Y_{ij} - \bar{Y}_i)$$

    - $Y_{ij} - \bar{Y}$: 관측치의 전체 변동
    - $\bar{Y}_i - \bar{Y}$ : 수준 i에서 관측치와 전체 평균의 차이, 요인(범주형 변수)에 의한 변동
    - $Y_{ij} - \bar{Y}_i$ : 관측치와 각 수준 평균 간 차이, 요인 수준i에 의해 설명될 수 없는 변동

  - 위의 식을 양변을 제곱하여 더하면(Sum of Squares), 아래와 같이 SST = SSTR+SSE로 표현할 수 있음

$$\sum_{i=1}^{r}\sum_{j=1}^{n}(Y_{ij} - \bar{Y})^2 = \sum_{i=1}^{r} n(\bar{Y}_i - \bar{Y})^2 + \sum_{i=1}^{r}\sum_{j=1}^{n}(Y_{ij} - \bar{Y}_i)^2$$

$$\text{SST} = \text{SSTR} + \text{SSE}$$

    - $SST$: 총제곱합(Total Sum of Squares)
    - $SSTR$: 처리제곱합(Treatment Sum of Squares)
    - $SSE$ : 오차제곱합(Error Sum of Squares)

- **일원분산분석표 (One-way ANOVA Table)**

| | Sum of Squares | degrees of freedom | Mean Square Error | F statistics |
|---|---|---|---|---|
| 처리 | SSTR | r-1 | MSTR | MSTR/MSE |
| 오차 | SSE | nT - r | MSE | |
| 전체 | SST | nT - 1 | | |

**F-통계량:**
**그룹간 변동성이 그룹내 변동성보다 커야하는 것을 의미!**

- F 통계량으로 요인들의 수준 간 평균의 차이여부를 검정
- F 통계량: 처리평균제곱 (MSTR)이 커지면 오차평균제곱(MSE)은 작아지며, F 통계량 값이 커지게 됨. 즉, 수준 평균들간에 차이가 큼
- 가설 검정
  - 귀무가설 H0 : $\mu_1 = \mu_2 = \ldots = \mu_r$
  - 대립가설 H1 : 모든 $\mu_i$ 는 같지 않다. $i = 1, 2, \ldots, r$
  - P-value < $\alpha$ 이면, H0 기각 (H0 reject)

- **다중비교 (Multiple Comparison)**
  - 분산분석에서 한 요인(Factor) 내 세 개 이상의 수준(Levels)의 집단 간에 평균의 차이를 검정
  - 그 결과 귀무가설 H0 기각하는 경우, 각 인자 수준들의 평균이 같지 않다는 결론을 내리게 됨
  - 이 때, 수준(Levels)에 따른 평균의 차이가 어떤 수준에서 발생했는지를 알고 싶을 때 사용

  - Pairwise T-test, Tukey's HSD test를 사용할 수 있으나, Pairwise T-test는 1종오류( True->False 로의 오류)의 가능성이 커져서 Tukey's HSD test 사용 권장
  - Tukey's HSD(honestly significant difference) test: Studentized range distribution 바탕으로 모든 가능한 두 수준들의 평균 차이 검정(pairwise post-hoc testing using Tukey HSD test)

- **다중비교 (Multiple Comparison)**
  - HSD 통계량

$$HSD_{ij} = q_\alpha(\gamma, -\gamma)\sqrt{\frac{MSE}{n}}$$

  - $\alpha$: 유의 수준, $\gamma$: 수준의 수, $n_T$: 관측치의 수
  - $MSE$: error mean square
  - $|\bar{Y}_i - \bar{Y}_j|$와 HSD 통계량 비교해서, $|\bar{Y}_i - \bar{Y}_j|$ 이 값이 더 크면 귀무가설(i와 j의 수준의 평균이 같음) 기각

| | group 1 | group 2 | group 3 |
|---|---|---|---|
| group 1 | - | 12 *** | -5 *** |
| group 2 | | - | -0.59 |
| group 3 | | | - |

- **이원분산분석(two-way ANOVA): 관측값 1개**
  - 2개의 요인(2 factors) 내의 요인 수준(factor levels) 간의 조합(combination)을 각각 개별 개별 집단으로(groups, treatments)로 고려하여, 요인수준 간 조합의 평균 차이 비교
  - 예를 들어, 요인(factor) A '크기'가 3개의 요인 수준(factor levels, 대,중,소)이 있고, 요인(factor) B '맛'이 2개의 요인 수준(factor levels, 맛있음, 맛없음)이 있으면, 총 그룹의 수는 3 x 2 = 6 개
  - (1) 관측값이 하나일 경우와 (2) 관측값이 2개 이상일 경우 (반복 실험을 할 경우)로 구분

| | 수준1 | … | 수준 b | 평균 |
|---|---|---|---|---|
| 수준 1 | $Y_{11}$ | … | $Y_{1b}$ | $\overline{Y_{1\cdot}}$ |
| … | … | … | … | |
| 수준 a | $Y_{a1}$ | … | $Y_{ab}$ | $\overline{Y_{a\cdot}}$ |
| 평균 | $\overline{Y_{\cdot 1}}$ | | $\overline{Y_{\cdot b}}$ | $\overline{Y_{\cdot\cdot}}$ |

- **이원분산분석(two-way ANOVA): 관측값 1개, Interaction 고려 안 하는 경우**
  - 이원분산분석모형의 편차 $(Y_{ij}-\bar{Y}_{..})$는 다음과 같이 구분할 수 있음
    - $Y_{ij}-\bar{Y}_{..} = (\bar{Y}_{i.} - \bar{Y}_{..}) + (\bar{Y}_{.j} - \bar{Y}_{..}) + (Y_{ij} - \bar{Y}_{i.} - \bar{Y}_{.j} - \bar{Y}_{..})$
      - $Y_{ij}-\bar{Y}_{..}$: *편차*
      - $\bar{Y}_{i.} - \bar{Y}_{..}$: *요인 A 편차*
      - $\bar{Y}_{.j} - \bar{Y}_{..}$: *요인 B 편차*
      - $Y_{ij} - \bar{Y}_{i.} - \bar{Y}_{.j} - \bar{Y}_{..}$: *오차*

  - 위의 식의 값을 제곱합한 후 아래식과 표처럼 나타낼 수 있음
    - SST: 총제곱합 (자유도 ab-1)
    - SSA: 요인A 수준 평균 간 제곱합 (자유도 a-1)
    - SSB: 요인B 수준 평균 간 제곱합 (자유도 b-1)
    - SSE: 오차 제곱합 (자유도 (a-1)(b-1) )

- **이원분산분석표(two-way ANOVA Table)**

| 요인 | squared sum | degrees of freedom | mean squared | F statistics |
|---|---|---|---|---|
| 요인 A | SSA | a-1 | MSA | MSA/MSE |
| 요인 B | SSB | b-1 | MSB | MSB/MSE |
| 오차 | SSE | (a-1)(b-1) | MSE | |
| 계 | SST | ab-1 | | |

**F-통계량:**
**그룹간 변동성이 그룹내 변동성보다 커야하는 것을 의미!**

- F 통계량 검정
  - 요인A 효과 검정 = MSA/MSE (F통계량)
    - H0 : A의 수준에 따라 평균 차이가 없다
    - H1 : A의 수준에 따라 평균 차이가 있다
  - 요인B 효과 검정 = MSB/MSE (F통계량)
    - H0 : B의 수준에 따라 평균 차이가 없다
    - H1 : B의 수준에 따라 평균 차이가 있다

- **이원분산분석표(two-way ANOVA Table): Interaction 고려 하는 경우**

| 요인 | squared sum | degrees of freedom | mean squared | F statistics |
|---|---|---|---|---|
| 요인 A | SSA | a-1 | MSA | MSA/MSE |
| 요인 B | SSB | b-1 | MSB | MSB/MSE |
| A*B | SSAB | (a-1)*(b-1) | MSAB | MSAB/MSE |
| 오차 | SSE | (a-1)(b-1) | MSE | |
| 계 | SST | ab-1 | | |

- 수식: SST=SSA+SSB+SSAB+SSE
- F 통계량 검정
  - 요인A 효과 검정 = MSA/MSE (F통계량)
    - H0 : A의 수준에 따라 평균 차이가 없다
    - H1 : A의 수준에 따라 평균 차이가 있다
  - 요인B 효과 검정 = MSB/MSE (F통계량)
    - H0 : B의 수준에 따라 평균 차이가 없다
    - H1 : B의 수준에 따라 평균 차이가 있다
  - 요인A와 B의 조합에 의한 Interaction 효과 검정 = MSAB/MSE (F통계량)
    - H0 : AB의 수준에 따라 평균 차이가 없다
    - H1 : AB의 수준에 따라 평균 차이가 있다

- **Interaction Effect?**

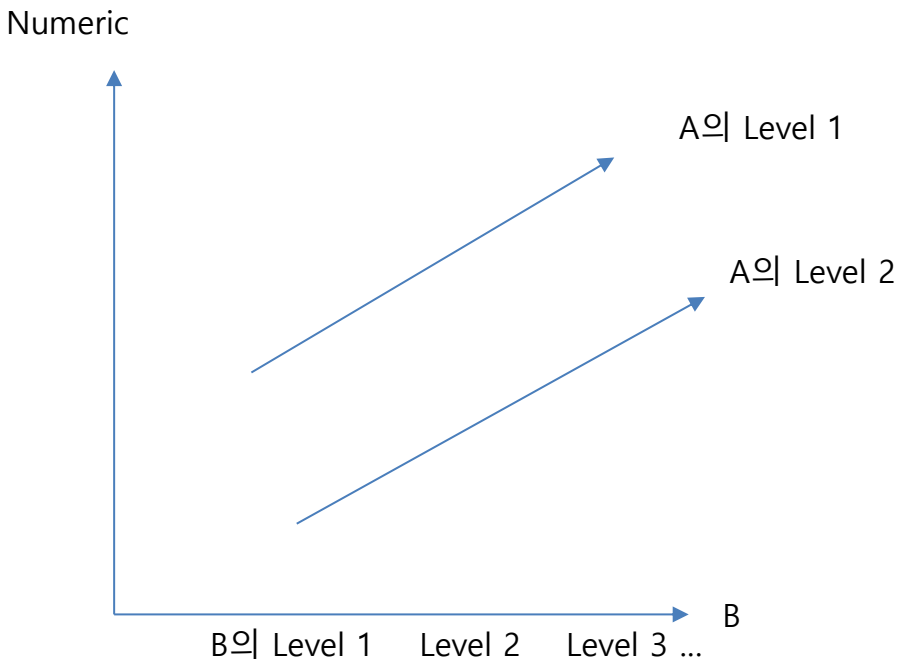


- A의 Effect (Main Effect)
- B의 Effect (Main Effect)
- AB의 Interaction Effect는 없음

- Two way Anova의 Interaction effect: A, B 두 변수 간의 조합이 만들어내는 결과
  - A, B 모두 Numeric 값에 영향을 주고 있음
  - 변수 간 조합에 의한 패턴으로 해석할 부분이 없고 그래서 평행이동하는 패턴

- **Interaction Effect?**

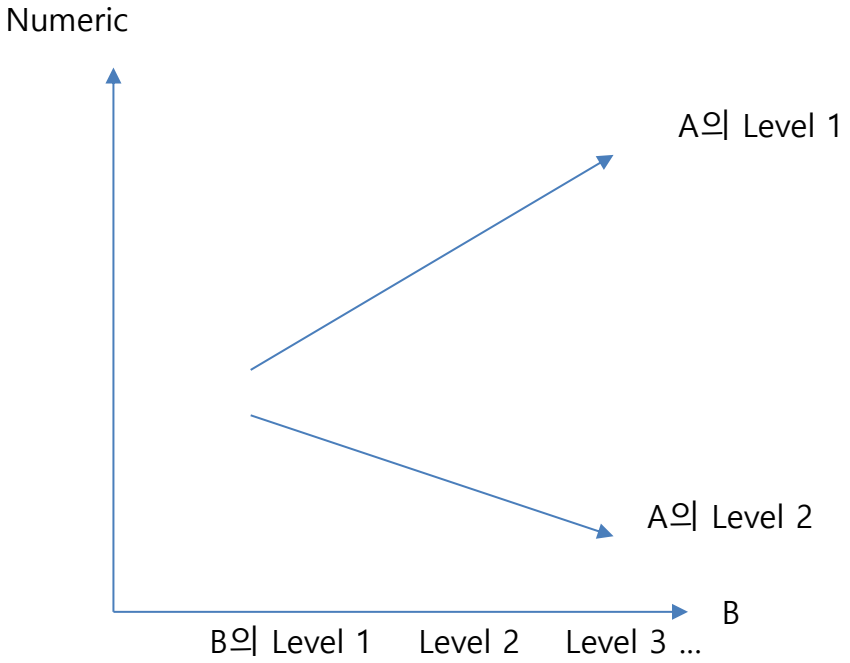


- A의 Effect (Main Effect)
- B의 Effect (Main Effect)는 없음
- AB의 Interaction Effect

- Two way Anova의 Interaction effect: A, B 두 변수 간의 조합이 만들어내는 결과
  - B가 단일 변수로는 효과가 없어 보이지만, A 변수와 함께 고려 시, 다른 패턴을 보여줌

**Dr. Genichi Taguchi**

- Born in Japan in 1924.
- Japan's Telephone Communications System
- Industrial Quality Movement in US
- Father of the "Taguchi Method", "Robust Engineering".
- Cost Driven Quality Engineering
- Applications of Engineering Strategies VS Advanced Statistical Techniques

Source: Sung Hyun Park, Robust Design and Analysis for Quality Engineering, Chapman Hall

## Factor Characteristics Relation Diagram

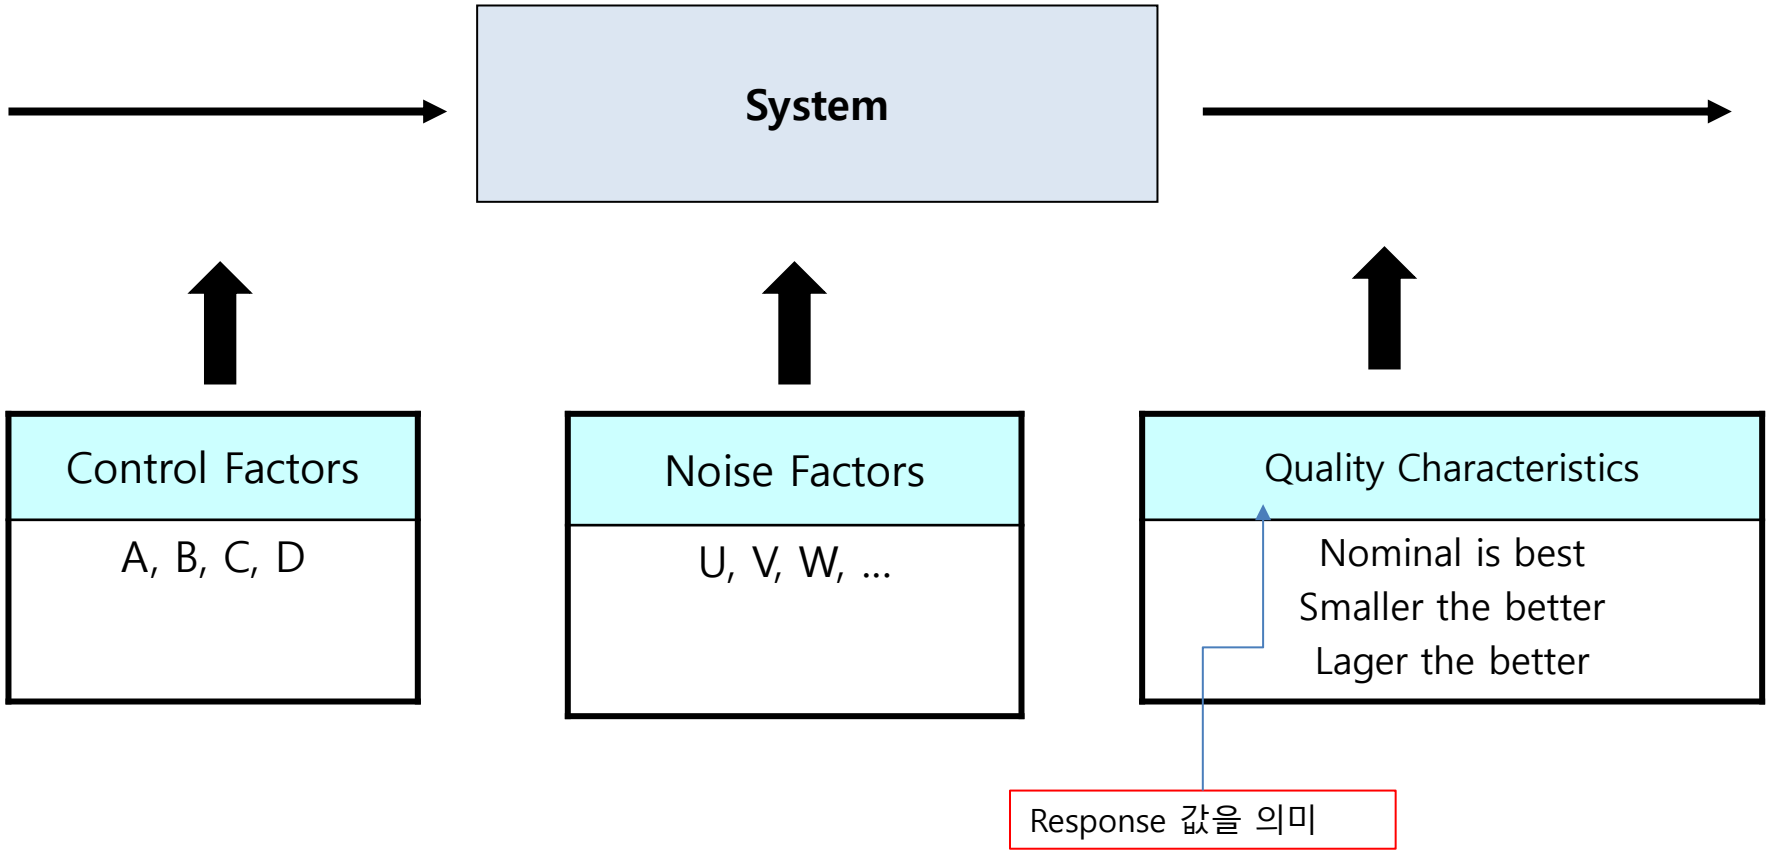

국립강릉원주대학교
GANGNEUNG-WONJU NATIONAL UNIVERSITY

**Industrial Data Science Lab**

Contact:
won.sang.l@gwnu.ac.kr
https://sites.google.com/view/idslab