Regression

2026 Spring

Industrial Data Science Lab & Unique AI

- **상관분석**

회사	1	2	3	4	5	6	7	8	9	10
광고비(X)	4	6	6	8	8	9	9	10	12	12
판매액(Y)	39	42	45	47	50	50	52	55	57	60

- 광고비가 증가함에 따라 판매액도 증가
- 선형으로 증가

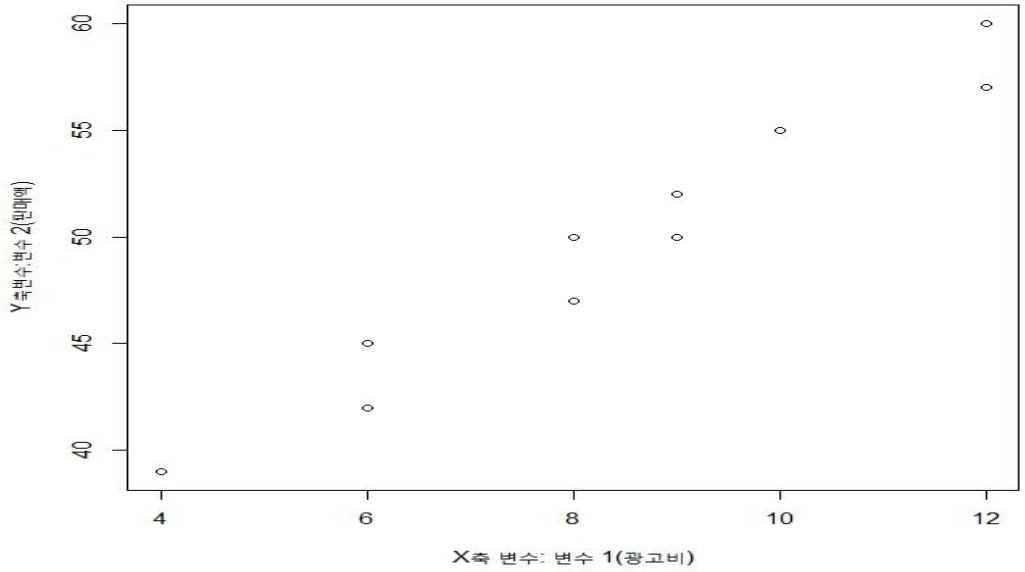

1. 상관 분석

- **공분산과 상관계수의 해석**
  - **공분산**
    - 두 변수의 상호 관계에 대한 강도를 나타냄
    - 두 변수의 원인/결과 관계를 나타내지 않는다.
      - Cov(x,y) > 0 x 와 y 는 같은 방향으로 움직이는 경향이 있음.
      - Cov(x,y) < 0 x 와 y 는 반대 방향으로 움직이는 경향이 있음
      - Cov(x,y) = 0 x 와 y 는 서로 독립이다.
  - **상관계수**
    - 두변수의 상호 관계를 나타내는 측도, 단위에 의존하지 않음
    - –1 과 1 사이의 값
      - –1 에 가까울수록 강한 음의 선형관계
      - 1 에 가까울수록 강한 양의 선형관계
      - 0 에 가까울수록 두 변수간의 선형관계는 없음 (다른 관계는 있을 수 있음)

- 산점도(Scatter plot)와 상관계수의 관계

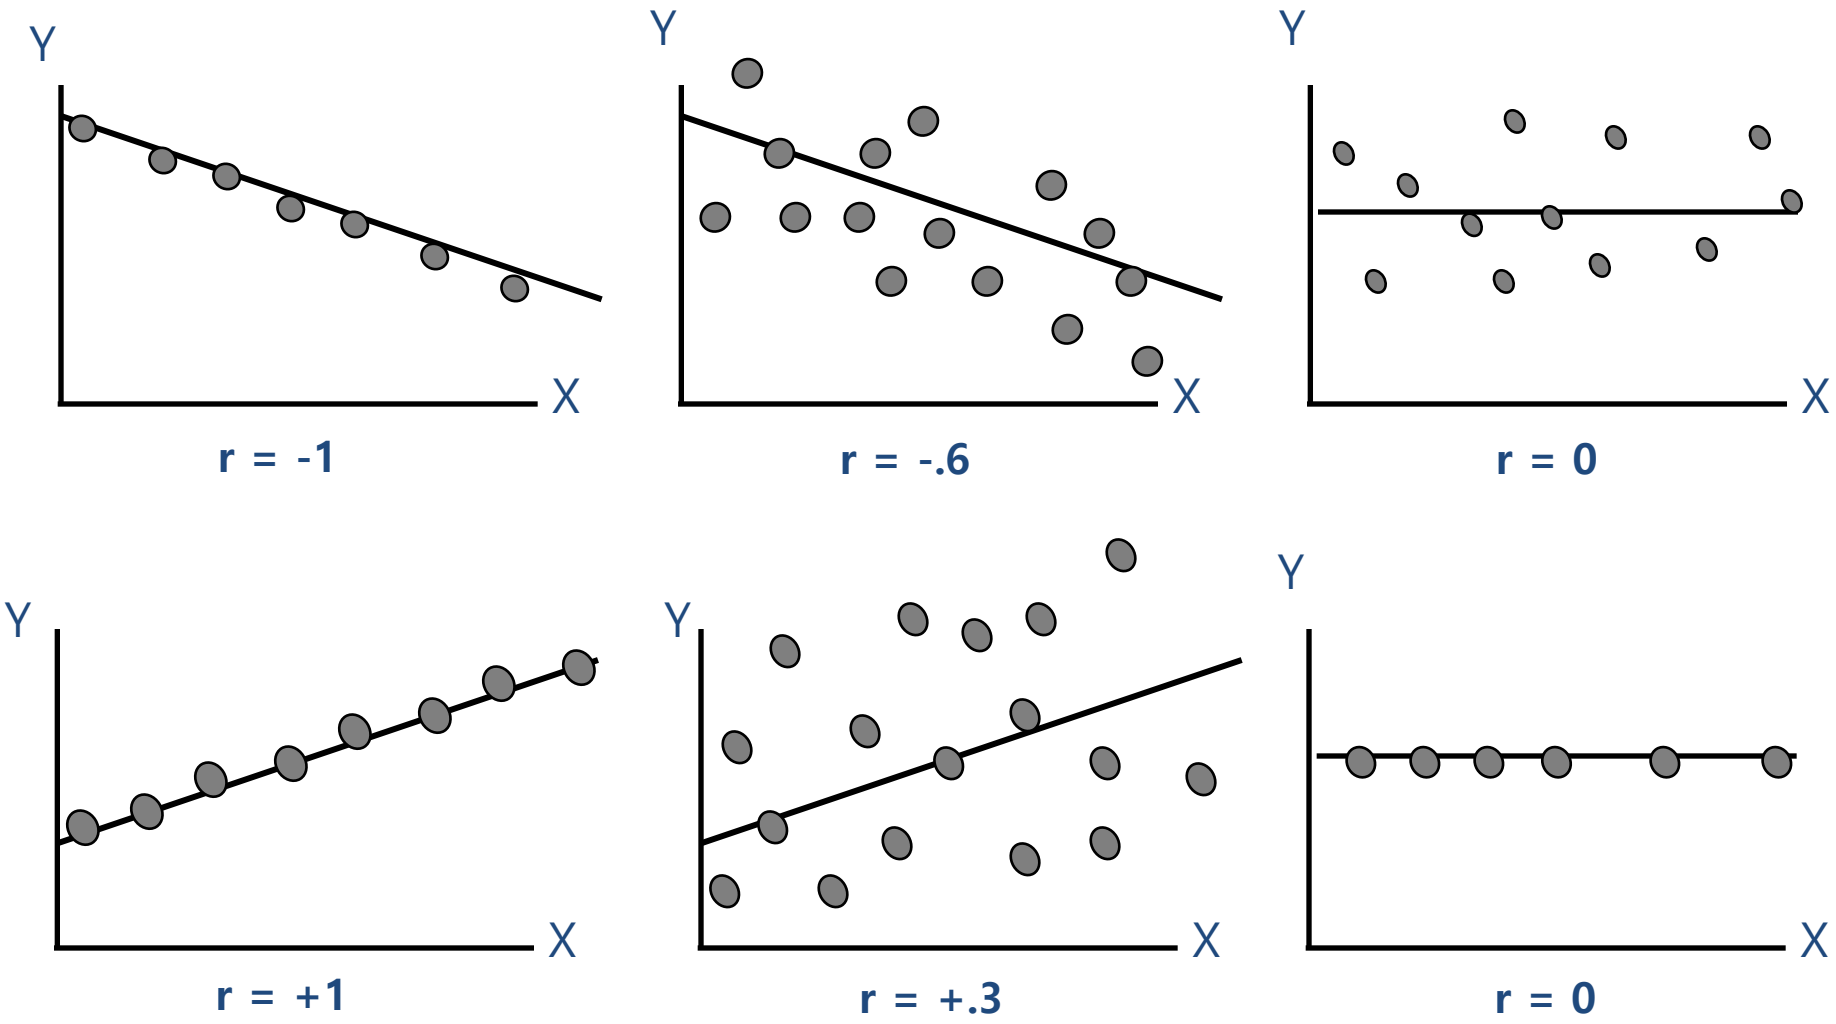

- **상관분석(Correlation Analysis)**

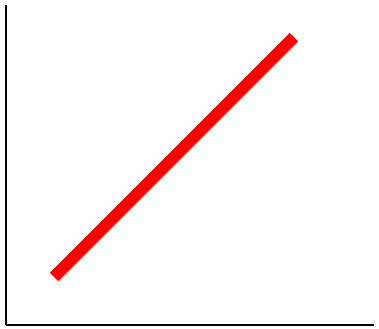

r = 1

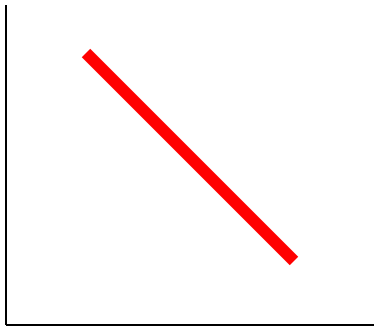

r = -1

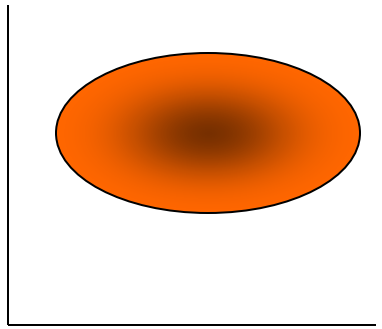

r = 0

- 상관관계 검정에 앞서 산점도를 이용하여 대략적인 관계를 파악
- 이상치 존재 여부 확인

1. 상관 분석

- **상관분석(Correlation Analysis)**
  - 두 변수(이변량 변수) 간 선형(상호의존)관계가 있을 경우 통계적으로 분석
    - 이변량 변수 : 같은 대상으로부터 측정된 두 변수
  - 상관계수 해석을 따름
    - 상관계수: 두 변수 간의 관련된 정도
    - 두 변수 간의 인과를 나타내지 않음

- **상관분석(Correlation Analysis)의 예**

  - 목적 : 두 개의 집단 간에 직선적인 관계가 존재하는 지 데이터를 이용하여 파악
  - 사례 : 아버지와 딸의 키, 소득과 지출, 흡연량과 폐암, 공정 온도&강도
  - 가설
    - 귀무가설(H_0) : $\rho = 0$ (상관 관계가 없다.)
    - 대립가설(H_1) : $\rho \neq 0$ (상관 관계가 있다.)

  - 상관 계수(Correlation Coefficient ; r)
    - 두 집단간의 직선적인 관계를 나타내는 지표로서, -1부터 +1 사이 의 값을 갖음
    - -1에 가까울수록 "음의 상관"을 +1에 가까울수록 "양의 상관"을 갖음

$$r = \frac{\sum(x_i - \bar{x})(y - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2 \sum(y_i - \bar{y})^2}}$$

- **상관분석 예제(Correlation Analysis)**

남자키	여자키
71	69
68	64
66	65
67	63
70	65
71	62
70	65
73	64
72	66
65	59
66	62

성인 남매의 키를 측정한 자료

이 자료를 바탕으로, 남매간의 신장에는 서로 관련이 있는지 알 수 있을까?

Pearson correlation of

남자 키 and 여자 키 = 0.558

P-Value = 0.074

2. 선형회귀분석 개요

- **Regression?**
  - 영국의 우생학자 Francis Galton (1822-1911)

  - 아버지와 아들의 키의 관계를 연구하며 Regression이라는 용어를 처음 사용
  - 아버지의 키가 큰 경우, 아들의 키는 작거나 아버지의 키가 작은 경우 아들의 키는 크며, 이들의 신장은 평균으로 가려는 경향
  - 부모의 키가 아들의 키에 영향을 주지만, 아들의 키는 그 세대 전체의 평균 신장으로 회귀

- **선형 회귀분석 (Linear Regression)**
- **목적 :**
  - 반응 인자(Response variable)와 하나 이상의 예측 인자(Predictor Variables) 사이의 관계를 표본으로부터 추정하여 수학적 모형을 만들고, 이를 통해 반응 인자에 대한 예측을 하는 방법

- **선형회귀는 데이터에 Straight line(기울기와 Y 절편)을 적합(fit)시키는 과정**
  - X변수들이 독립변수/Predictor 변수, Y변수가 종속변수/ Response 변수
  - 선형회귀를 통해 얻어진 Line은 기울기와 Y절편으로 나타내며, 알려진 X값에 대한 Y 값 예측

2. 선형회귀분석 개요

- 종류(인자 수에 의한 분류)
  - *단순회귀분석(Simple Linear Regression Analysis)*

    : 반응인자 1개와 예측 인자 1개로 구성 (예) $Y = b_0 + b_1X_1$
  - *다중 회귀분석(Multiple Regression Analysis)*

    : 반응인자 1개와 두 개 이상의 예측 인자로 구성 (예) $Y= b_0 + b_1X_1 + b_2X_2 + \dots +b_kX_k$

- Residual(잔차): 이렇게 예측된 Y와 실제 Y의 차이
  - 관측치가 Straight line에서 얼마나 떨어져있는지를 나타냄
  - Least squares : 기울기와 Y절편인 b0 와 b1 를 구하는 방법, Residual errors의 Square의 합을 최소화하는 기울기와 절편을 찾음

- 유의사항
  - 통계적 추론을 하기 위해서는, 잔차에 대한 가정이 필요
  - 등분산성, 선형성, 정규성 (선형성은 변수와 잔차의 Scatter plot 이용하여 확인)

- **선형회귀 검정**
  - 회귀 계수에 대한 검정
  - 회귀계수=0이면 그 회귀계수에 해당하는 독립변수는 종속변수와 관계가 없다고 해석
  - 회귀계수=0을 H0으로 보고, 다음의 통계량을 통해 검정

$$t = \frac{\hat{b}}{s.e.(\hat{b})}$$

  - 검정통계량에 대한 확률을 구해서 그 확률이 유의수준보다 작은 경우 H0을 기각
  - 회귀계수는 0이 아니며, 구해진 회귀계수는 유의함

2. 선형회귀분석 개요

- **선형회귀분석**
  - 선형회귀분석의 변수
    - 독립변수(Independent variable : X)
      - 종속변수에 영향을 주는 변수(설명변수. 외생변수 등)
      - 종속변수를 설명하는데 이용하는 변수
      - 예 : 광고비와 판매액의 관계에서 광고비
    - 종속변수(Dependent variable : Y)
      - 서로 관계를 가지고 있는 변수들 중에서 다른 변수에 의해 영향을 받은 변수(반응변수, 내생변수 등)
      - 설명하고자 하는 변수
      - 주로 다른 변수의 반응으로 관측되는 변수
      - 예 : 광고비와 판매액의 관계에서 판매액
  - 회귀분석(Regression analysis):하나 이상의 독립변수를 이용하여 종속변수를 예측하는 통계적 분석
    - 단순선형회귀분석 : 독립변수가 하나인 경우
    - 다중선형회귀분석 : 독립변수가 2개 이상의 경우

2. 선형회귀분석 개요

- **단순선형회귀모형**

  - X 와 Y의 관계를 선형함수(선형 방정식)로 표현

  - 단순선형회귀 모형

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

  - β_0 와 β_1: 미지의 모수, 회귀계수(Regression coefficients)

  - ε : 회귀식으로 표현할 수 없는 오차항

- **단순선형회귀모형**

모집단의 Y 절편

모집단의 기울기 또는 회귀계수

독립변수

오차항

종속변수

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

- **단순선형회귀모형**

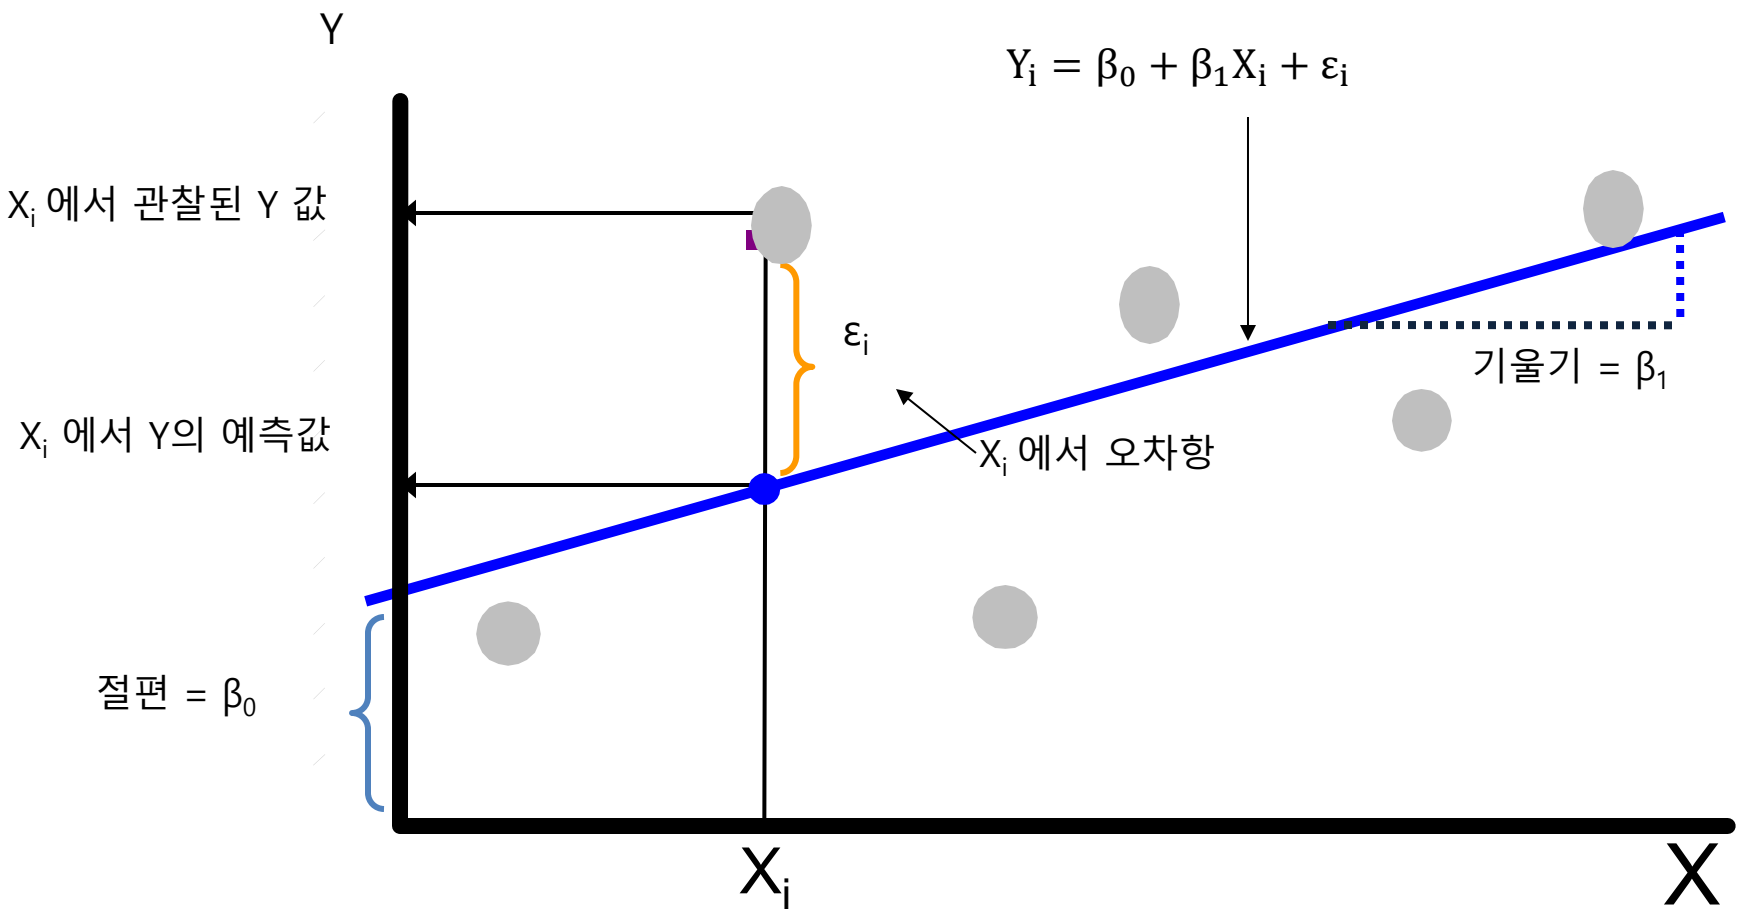
Y
$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$
X_i 에서 관찰된 Y 값
ε_i
기울기 = β_1
X_i 에서 Y의 예측값
X_i 에서 오차항
절편 = β_0
X_i
X

- **회귀 모형 기본 가정**
  - X 와 Y는 오차항(ε)을 포함하는 선형관계(Linear Relation)
    - 오차항 (ε_i) 의 평균은 0
      - E(ε_i)=0 (i=1, 2, ….,n)
    - (등분산성) 모든 ε_i 의 분산은 σ^2 으로 동일
      - Var(ε_i)= σ^2 (i=1, 2, ….,n)
    - (독립성) 오차항 ε_i 들은 서로 독립
      - 서로 다른 i, j 에 대하여 E(ε_i ε_j)=0
    - (정규성) 오차항 ε_i 들은 정규 분포
      - ε_i ~N(0, σ^2) (i=1, 2, ….,n)

- **회귀계수 추정**
  - 표본회귀식 : 표본을 이용하여 추정된(적합된) 회귀식

기울기 추정치

절편 추정치

i 번째값의 종속변수 추정치

$$\hat{y}_i = b_0 + b_1 x_i$$

i 번째 관찰값의 x 값

- 잔차 e (residual) : 예측된 값과 실제 관찰값의 차이

$$e_i = (y_i - \hat{y}_i) = y_i - (b_0 + b_1 x_i)$$

- **최소제곱법 (Least Square Estimation)**
  - 잔차: 적합된 회귀식에서 계산된 예측치($\hat{y}_i$)와 관찰치(y_i)의 차이
  - LSE: 잔차들의 제곱의 합이 최소가 되도록 회귀계수를 추정하는 방법
    - 다음의 식을 최소화 하는 b_0 와 b_1의 값을 구하기

$$\min\ \mathrm{SSE} = \min \sum e_i^2$$

$$= \min \sum (y_i - \hat{y}_i)^2$$

$$= \min \sum [y_i - (b_0 + b_1 x_i)]^2$$

위의 식을 b_0 과 b_1 에 대하여 편미분하여 0으로 놓고
b_0 과 b_1 에 대하여 풀어서 구해지는 값

- **최소제곱 추정량**
  - 기울기에 대한 추정량

$$b_1 = \frac{s_{XY}}{s_X^2} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2} = r\,\frac{s_Y}{s_X}$$

  - 절편에 대한 추정량

$$b_0 = \bar{y} - b_1\bar{x}$$

- **단순선형회귀모형: 기울기와 절편에의 해석**
  - b0 : x 가 0 의 값을 가질 때 y 값의 추정량
  - b1 : x 가 한 단위 증가할 때 y 의 증가분

판매액 (Y)	광고비 (X)
39	4
42	6
45	6
47	8
50	8
50	9
52	9
55	10
57	12
60	12

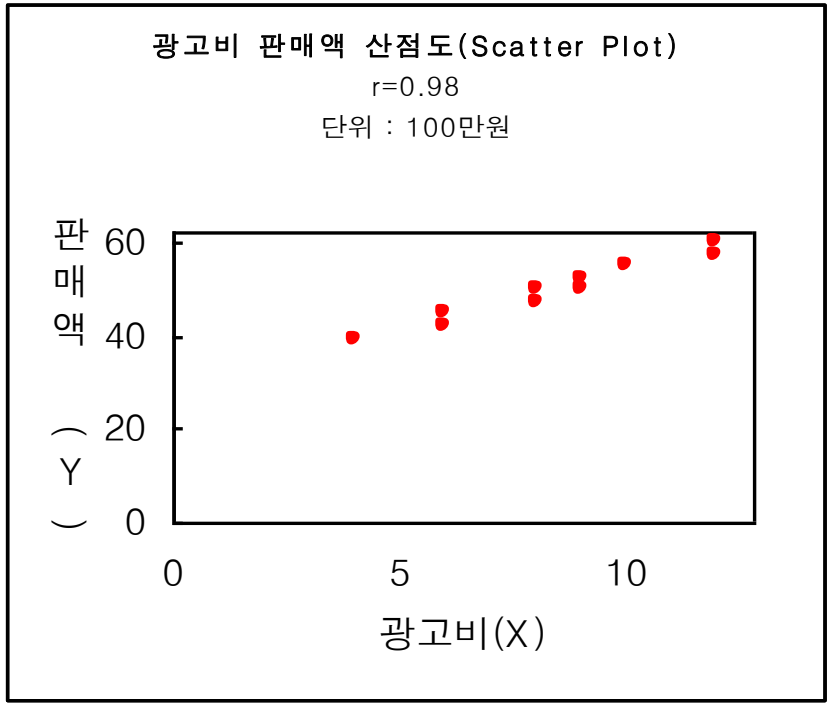

- **단순선형회귀모형**

  - 기울기에 대한 추정값

$$b_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2} = \frac{151.2}{60.4} = 2.503$$

  - 절편에 대한 추정값

$$b_0 = \bar{y} - b_1\bar{x} = 49.7 - 2.5033 \times 8.4 = 28.627$$

  - 적합된 회귀식

$$\hat{y}_i = b_0 + b_1 x_i = 28.627 + 2.5033 x_i$$

- b0 =28.627 :
- 광고비가 0일때 판매액은 약 2천8백만원 예상

- b1=2.5033 :
- 광고비가 1단위 증가 시 판매액 평균적으로 약 2.5백만 원 증가

- **단순선형회귀모형**

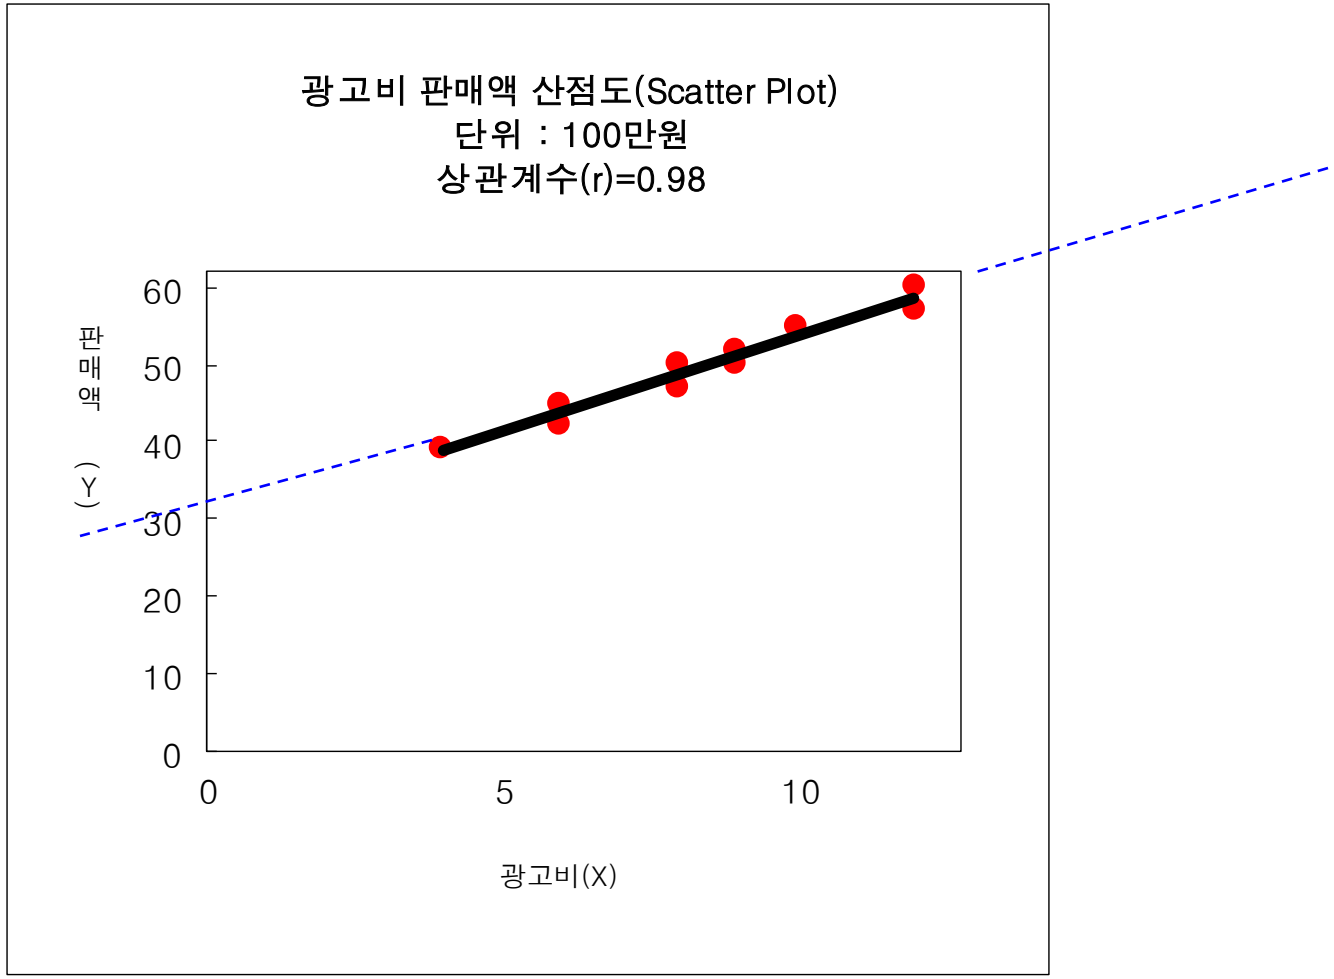
광고비 판매액 산점도(Scatter Plot)
단위 : 100만원
상관계수(r)=0.98
판매액 (Y)
60
50
40
30
20
10
0
0
5
10
광고비(X)

- **회귀직선의 적합도**

  - Y의 관측값들이 가지는 총변동 SST

$$SST = SSR + SSE$$

총 제곱합

$$SST = \sum (y_i - \bar{y})^2$$

회귀제곱합

$$SSR = \sum (\hat{y}_i - \bar{y})^2$$

오차제곱합

$$SSE = \sum (y_i - \hat{y}_i)^2$$

$\bar{y}$: 종속변수의 평균
y_i : 종속변수의 관찰값
$\hat{y}_i$: x_i 에 대한 종속변수의 추정값

3. 선형회귀분석

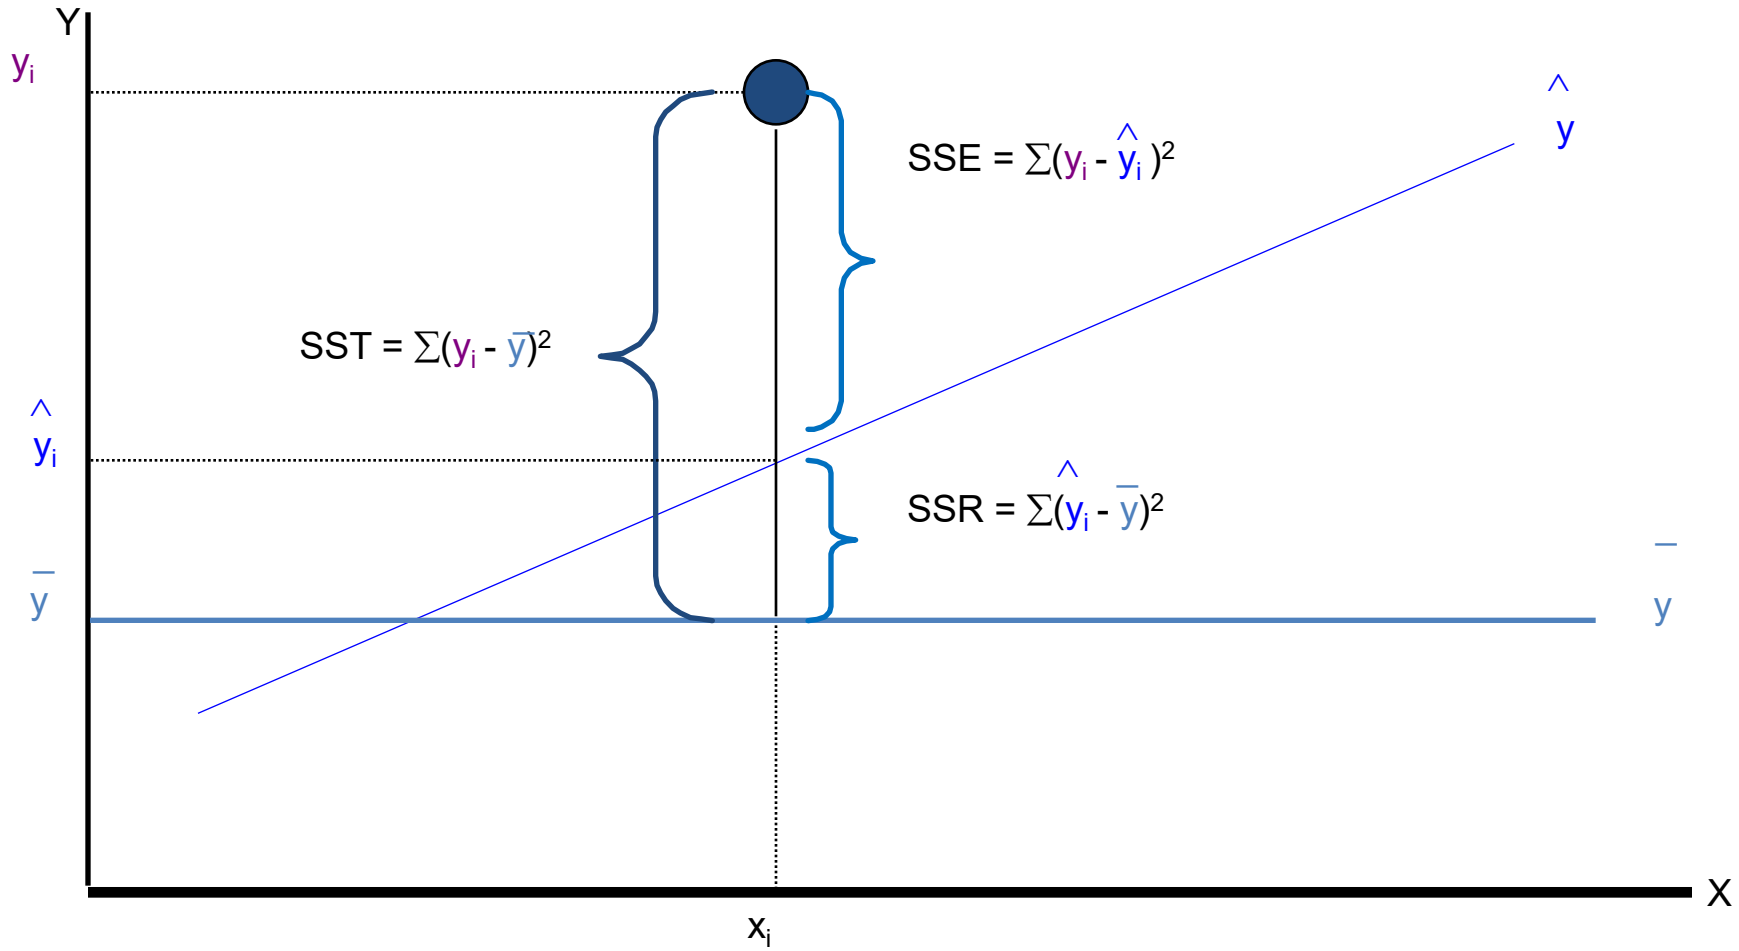

- SST = total sum of squares , Y의 관측값들이 가지는 총변동을 나타내는 제곱합
- SSR = regression sum of squares, Y의 총변동 중 회귀식에 의해 설명되는 변동을 나타내는 제곱합
- SSE = error sum of squares , 잔차들의 제곱합으로 Y의 총변동 중 회귀식에 의해서 설명되지 않는 변동

- **결정계수(Coefficient of Determination)**

  - 결정계수(R^2) : 총변동 SST 중에서 회귀에 의해 설명된 변동 SSR이 차지하는 비

$$R^2 = \frac{SSR}{SST} = \frac{\text{회귀식에 의해 설명된 변동}}{\text{총 변동}}$$

  - 결정계수의 값은 항상 0과 1 사이
    - 1에 가까울 수록 표본들이 회귀직선 주위에 밀집되어 있음
    - 추정된 회귀식이 관측값을 잘 설명하고 있음

$$0 \leq R^2 \leq 1$$

➢ 결정계수

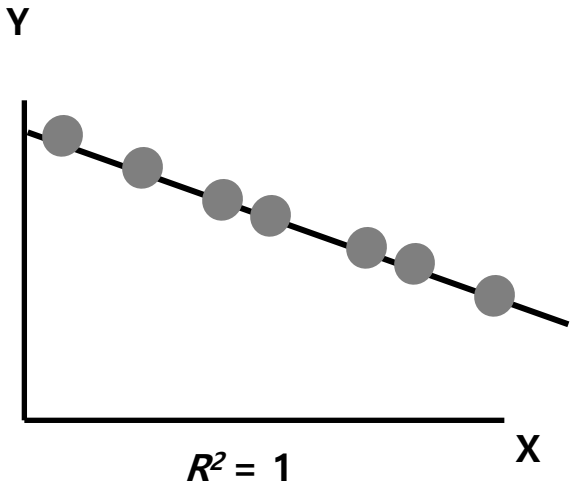

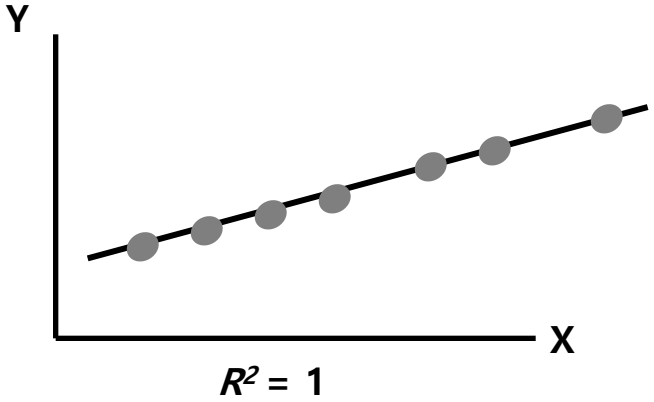

- 선형관계
- Y는 X에 의해서 100% 설명

- **결정계수**

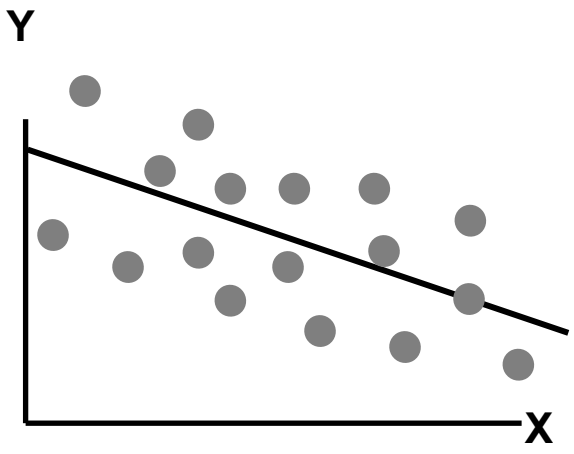

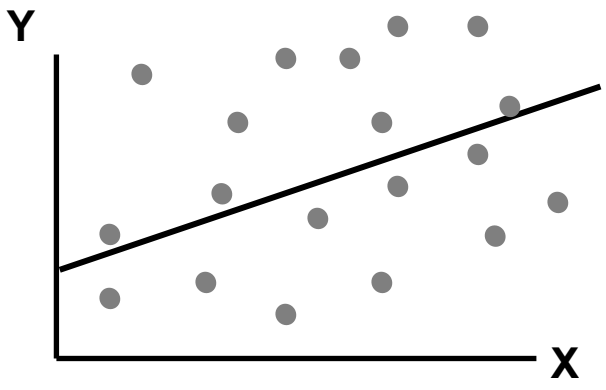

$0 < R^2 < 1$

- X 와 Y 의 선형관계
- Y는 X에 의해 r^2 X100% 설명

- **결정계수**

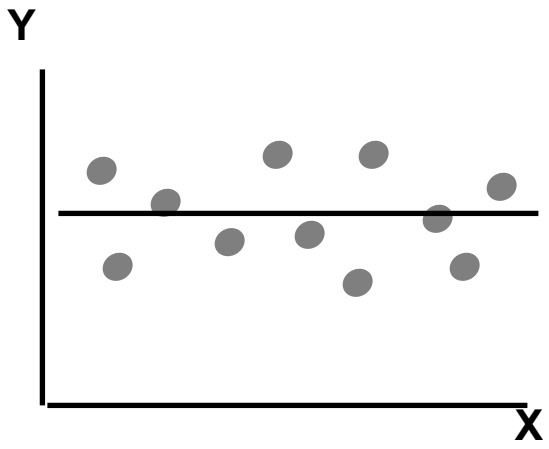

$R^2 = 0$

$R^2 = 0$

- X 와 Y의 선형관계가 없음
- Y는 X에 의해 설명되지 않음

$$R^2 = r_{xy}^2$$

- 결정계수는 X와 Y의 표본상관계수의 제곱과 일치

- **회귀분석의 분산 분석표**

요인	제곱합(SS)	자유도(df)	평균제곱(MS)	F비
R(회귀)	SSR	1	$MSR = \frac{SSR}{1}$	$F = \frac{MSR}{MSE}$
E(오차)	SSE	n-2	$MSE = \frac{SSE}{n-2}$	
T(전체)	SST = SSR+SSE	n-1		

- **가설검정**

$$F = \frac{MSR}{MSE} \sim F(1, n-2)$$

H_0: $\beta_1 = 0$ vs H_1: $\beta_1 \neq 0$

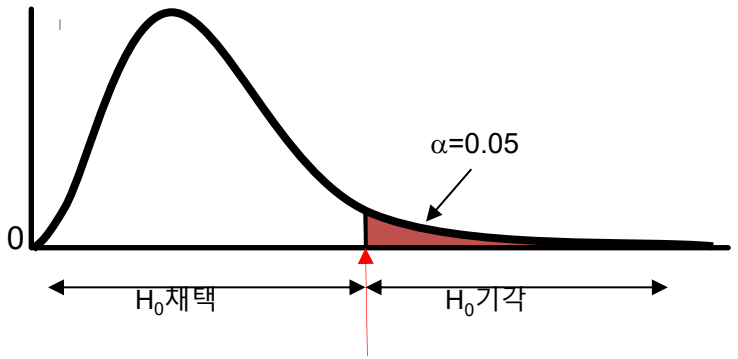

- 귀무 가설 기각
  - 만약 β_1 이 0 이 아니라면 가정된 회귀식이 타당하여 Y의 변동이 회귀식에 의해 설명, 이 경우 F값이 크게 됨
  - F 값이 충분히 크면 β_1 이 0 이 아니라고 해석

- 귀무가설이 맞는 경우
  - 검정통계량 F는 자유도가 (1,n-2)인 F 분포
  - $F > F_{1,\ n-2,\alpha}$이면 귀무가설 기각

- **기울기 (β1)에 대한 가설 검정**
  - 모집단의 기울기가 0 인지 ?
    - H_0: $\beta_1 = 0$(선형관계가 없음)
    - H_1: $\beta_1 \neq 0$(선형관계가 존재)

$|t| = \left|\frac{b_1-\beta_1}{SE(b_1)}\right|$ 와 유의수준a에서의 통계량값과 비교$(t_{n-2,\alpha/2})$

  - 모집단의 절편이 0 인지
    - H_0: $\beta_0 = 0$
    - H_1: $\beta_0 \neq 0$

$|t| = \left|\frac{b_0-\beta_0}{SE(b_0)}\right|$ 와 유의수준a에서의 통계량값과 비교$(t_{n-2,\alpha/2})$

- **Y의 평균값 E(Y|x_0)=$\mu_{Y|x_0}$**
  - X의 임의의 점 X=x0 에서, 종속변수 Y는 평균값 E(Y| x_0)= β_0 + β_1 x_0
  - X=x_0인 동일 수준에서 Y의 평균값을 의미
  - E(Y| x_0)에 대한 점 추정량
    - $\hat{y}_0 = b_0 + b_1 x_0$
    - $\hat{y}_0$의 신뢰 구간 : $\hat{y}_0 \pm t_{n-2,\frac{\alpha}{2}} SE(\hat{y}_0)$
    - 주어진 X의 SE가 크면 신뢰구간의 폭도 넓어짐
    - 신뢰대(Confidence Band): X의 각 점에서 Y평균에 대한 신뢰 구간을 구하여 상/하한을 연결한 곡선

- **Confidence Band**

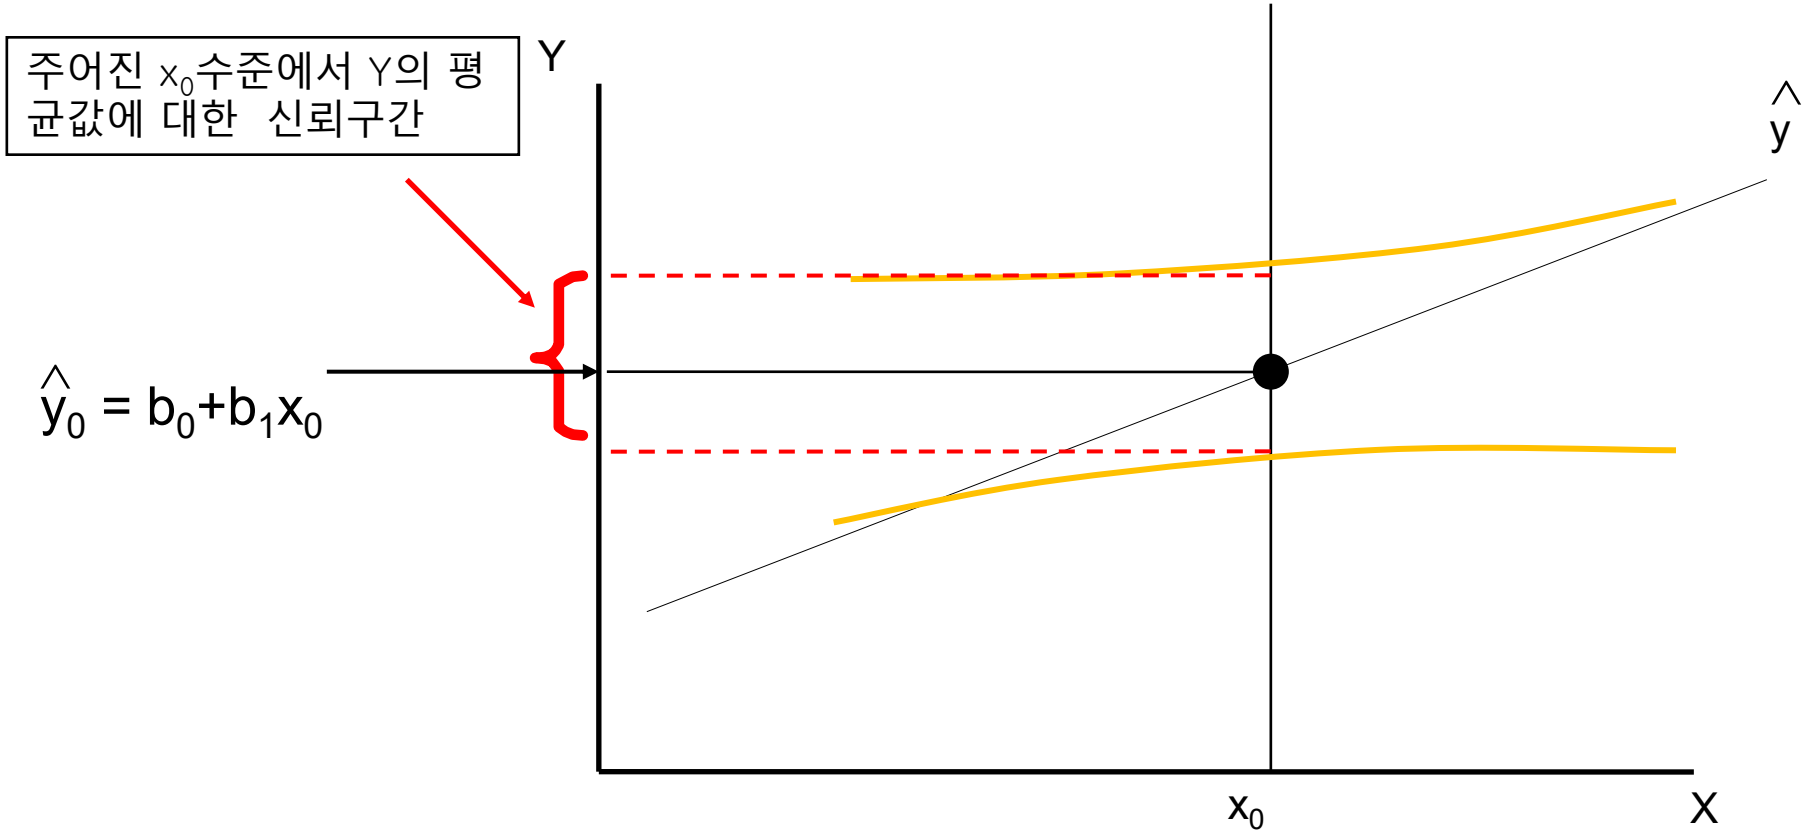

- **잔차 분석(Residual Analysis)**

  - 데이터가 회귀 분석의 기본 가정들을 만족하는지 잔차 e의 산점도로 분석

    - 자료의 선형성: '잔차 vs 독립변수' 산점도
    - 오차항의 등분산성: '잔차 vs 예측치' 산점도
    - 오차항의 독립성과 E(ε_i)=0 : '잔차 vs 관측순서' 산점도 주로 이용.
    - 오차항의 정규성 : 잔차의 히스토그램 확인, Q-Q plot 등

  - 위의 산점도에서 잔차들이 0을 중심으로 랜덤하게 나타나면 각 가정을 만족

- 잔차 분석(Residual Analysis) - 선형성 점검

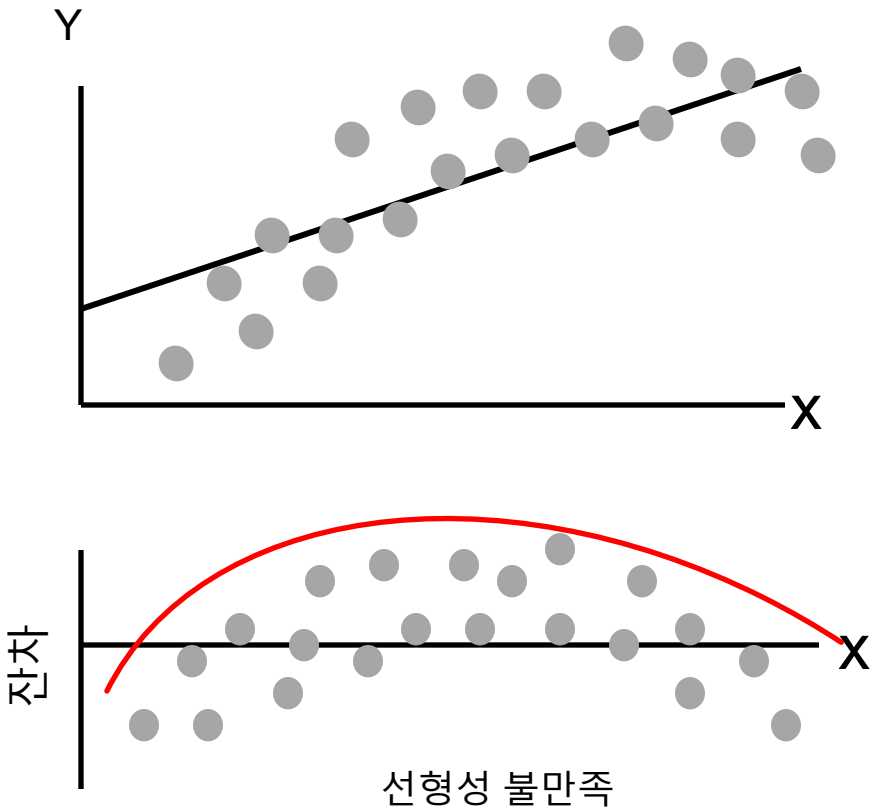

선형성 불만족

(비선형)

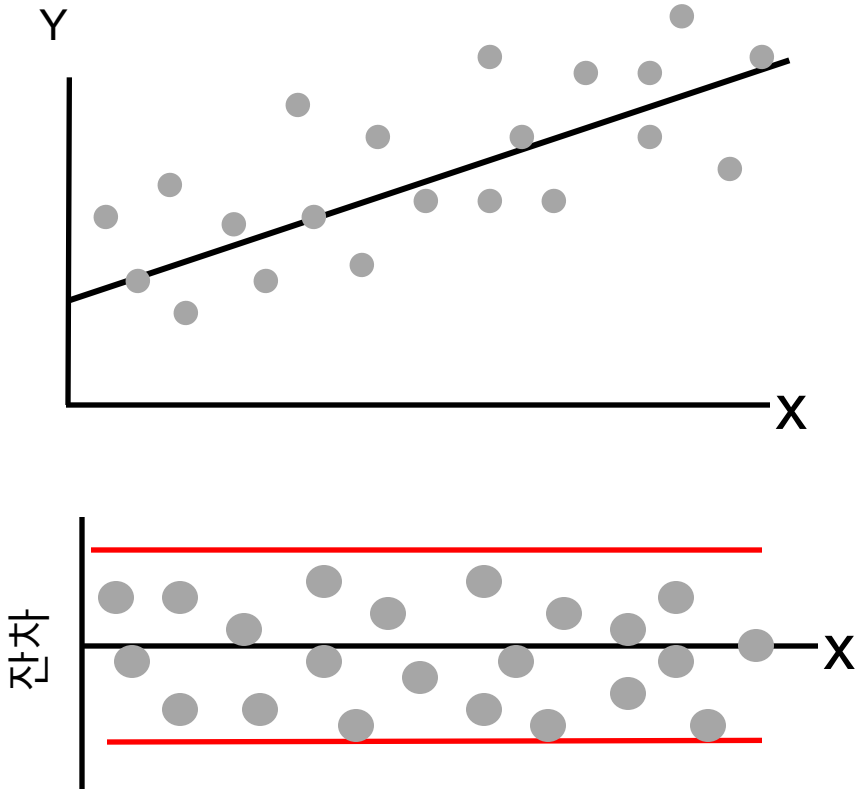

선형성 만족

- 잔차 분석(Residual Analysis) - 등분산성 점검

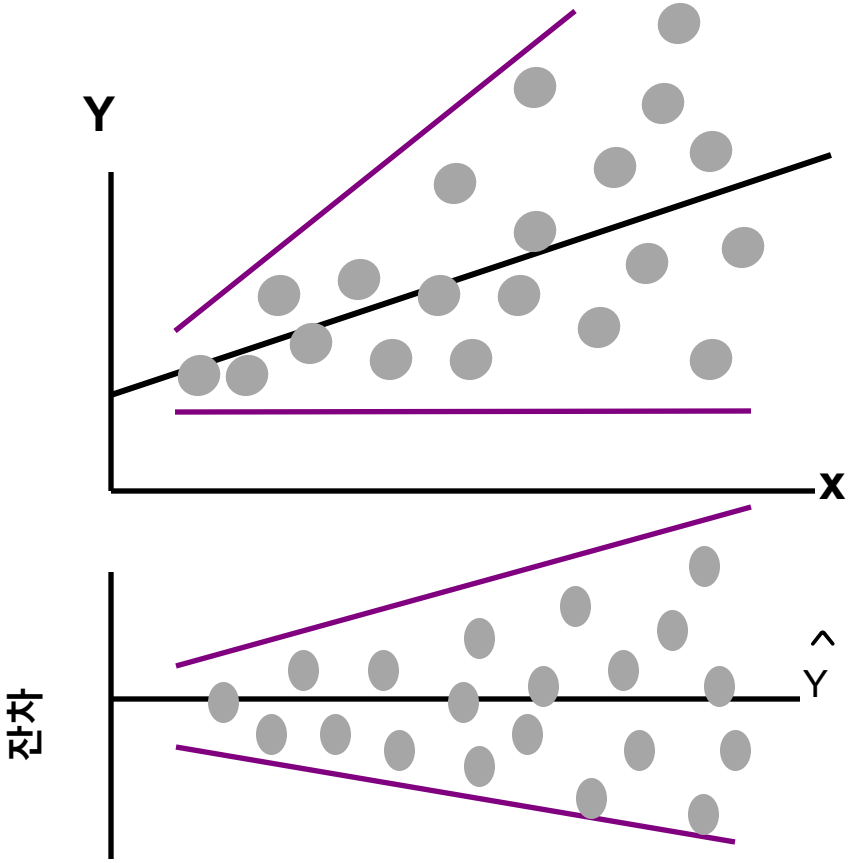

이분산

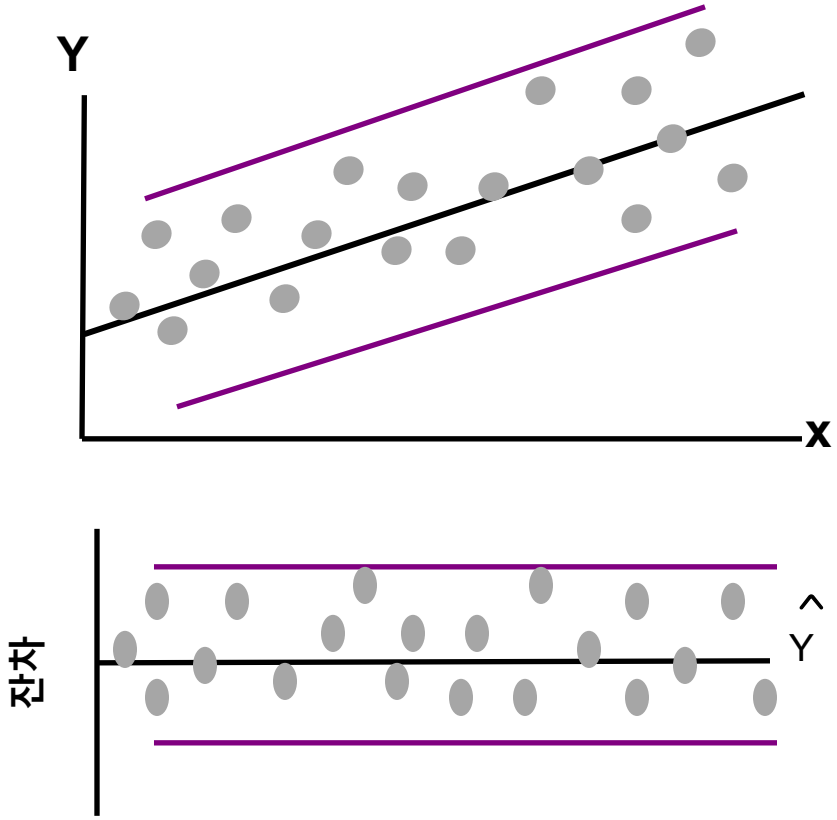

등분산
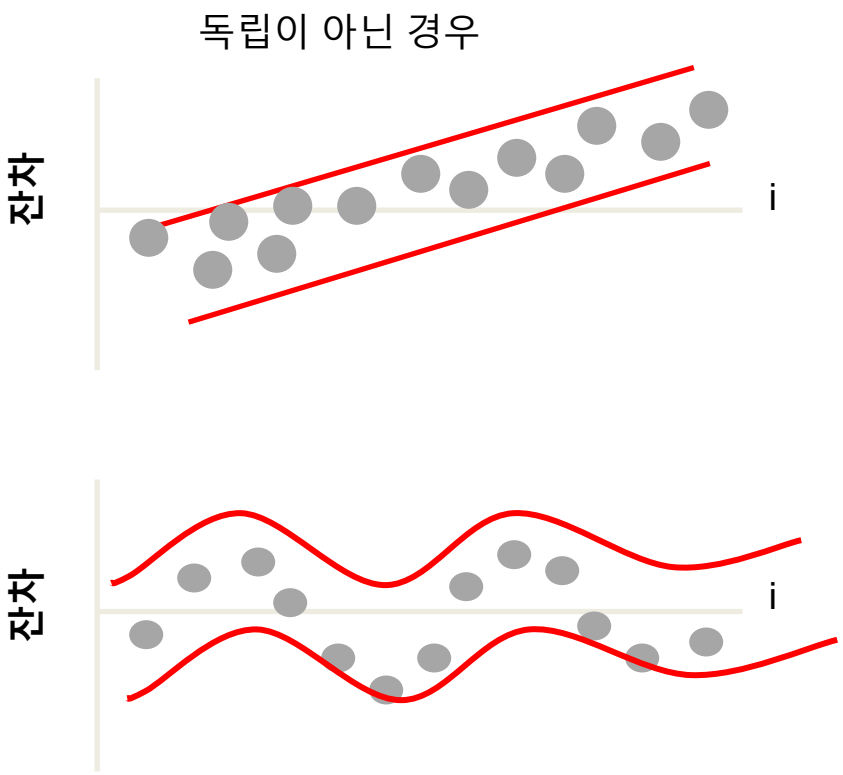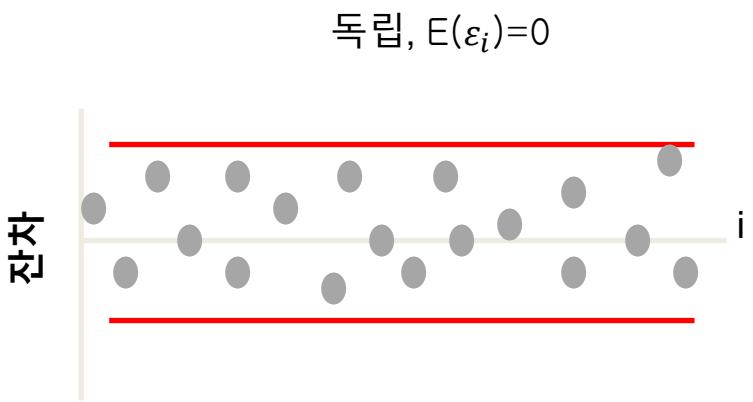
- **잔차 분석(Residual Analysis) - 오차항의 평균=0, 오차항은 서로 독립에 대한 점검**